

Análisis de asociación

Reglas de asociación, algoritmos clásicos y ejemplos en R

Minería de Datos

Clase práctica

30 de junio de 2026

Objetivos de la clase

- Comprender el problema de descubrir asociaciones frecuentes en datos transaccionales.
- Definir itemsets, reglas, soporte, confianza, lift y otras medidas de interés.
- Revisar los algoritmos clásicos: Apriori, Eclat y FP-Growth.
- Implementar un flujo de trabajo en R usando `arules` y `arulesViz`.
- Interpretar reglas de asociación y discutir sus limitaciones.

Pregunta central:

¿Qué elementos tienden a aparecer juntos más frecuentemente de lo esperado?

- Canasta de compras: pan, leche, mantequilla.
- Diagnóstico: síntomas, exámenes y enfermedad.
- Web: páginas visitadas en una misma sesión.
- Biología: genes, mutaciones o rutas alteradas en conjunto.

Idea

Una regla de asociación resume una relación condicional frecuente:

$$A \Rightarrow B$$

“si aparece A, también suele aparecer B”.

Datos transaccionales

Transacción	Ítems observados
T1	pan, leche, huevos
T2	pan, mantequilla
T3	leche, huevos, cereal
T4	pan, leche, mantequilla
T5	pan, leche, huevos, mantequilla

Cada fila representa una unidad de análisis; cada ítem puede estar presente o ausente. El formato usual es una matriz binaria dispersa: muchas columnas, muchos ceros.

Conceptos básicos

Ítem e itemset

Un **ítem** es una característica discreta. Un **itemset** es un conjunto de ítems, por ejemplo {pan, leche}.

Regla de asociación

Una regla se escribe como:

$$X \Rightarrow Y, \quad X \cap Y = \emptyset$$

Donde X es el antecedente y Y el consecuente.

Ejemplo

$$\{pan, mantequilla\} \Rightarrow \{leche\}$$

Interpretación: entre las transacciones con pan y mantequilla, una fracción relevante también contiene leche.

Soporte de un itemset: proporción de transacciones que contienen ese conjunto.

$$\text{support}(X) = \frac{\#(X)}{N}$$

Soporte de una regla:

$$\text{support}(X \Rightarrow Y) = \text{support}(X \cup Y)$$

Interpretación

El soporte mide frecuencia absoluta relativa. Es útil para filtrar patrones demasiado raros, aunque patrones raros pueden ser importantes en algunos dominios.

Confianza

Confianza: probabilidad empírica de observar Y dado que se observa X .

$$\text{confidence}(X \Rightarrow Y) = \frac{\text{support}(X \cup Y)}{\text{support}(X)}$$

Ejemplo

Si 40 % de las transacciones tienen pan y 30 % tienen pan y leche:

$$\text{confidence}(\{pan\} \Rightarrow \{leche\}) = \frac{0,30}{0,40} = 0,75$$

Cuidado

Una confianza alta no implica que la asociación sea interesante: el consecuente puede ser muy frecuente por sí solo.

Lift: compara la co-ocurrencia observada con la esperada bajo independencia.

$$\text{lift}(X \Rightarrow Y) = \frac{\text{confidence}(X \Rightarrow Y)}{\text{support}(Y)}$$

- lift = 1: X e Y aparecen juntos como se esperaría por azar.
- lift > 1: asociación positiva.
- lift < 1: asociación negativa.

Idea clave

El lift corrige parcialmente el problema de consecuentes muy frecuentes.

Otras medidas de interés

Medida	Uso principal
Leverage	Diferencia entre co-ocurrencia observada y esperada.
Conviction	Mide cuánto se reduce el error al usar la regla.
Coverage	Proporción de transacciones cubiertas por el antecedente.
Chi-cuadrado	Evalúa independencia entre antecedente y consecuente.
Fisher exacto	Alternativa para tablas pequeñas o eventos raros.

En la práctica se combinan varias medidas: soporte mínimo, confianza mínima, lift alto y una interpretación coherente con el dominio.

Principio clave

Si un itemset no es frecuente, ningún superconjunto suyo puede ser frecuente.

$$\text{support}(X \cup Z) \leq \text{support}(X)$$

- Esta propiedad permite podar el espacio de búsqueda.
- Es la base del algoritmo Apriori.
- Reduce drásticamente el número de combinaciones evaluadas.

Algoritmo Apriori: intuición

- 1 Encontrar todos los ítems frecuentes de tamaño 1.
- 2 Generar candidatos de tamaño 2 combinando ítems frecuentes.
- 3 Eliminar candidatos con subconjuntos no frecuentes.
- 4 Contar soporte en la base de transacciones.
- 5 Repetir para itemsets de tamaño k .
- 6 Generar reglas desde los itemsets frecuentes.

Costo computacional

Apriori puede requerir muchas pasadas sobre los datos y generar muchos candidatos, especialmente con soporte bajo.

Entrada

Base transaccional D , soporte mínimo s_{min} , confianza mínima c_{min} .

- ❶ L_1 = itemsets frecuentes de tamaño 1.
- ❷ Para $k = 2, 3, \dots$ mientras L_{k-1} no esté vacío:
 - ❶ Generar candidatos C_k desde L_{k-1} .
 - ❷ Podar candidatos con subconjuntos no frecuentes.
 - ❸ Contar soporte de cada candidato en D .
 - ❹ Guardar en L_k los candidatos con soporte $\geq s_{min}$.
- ❸ A partir de $\cup_k L_k$, generar reglas que cumplan c_{min} .

Idea: representar cada ítem por la lista de transacciones en que aparece.

- Usa formato vertical.
- El soporte de un itemset se calcula como intersección de listas.
- Suele ser eficiente cuando las listas son manejables.

Ejemplo

pan T1, T2, T4, T5

leche T1, T3, T4, T5

$\{pan, leche\} : T1, T4, T5$

Soporte = 3/5.

Algoritmo FP-Growth

- Evita generar candidatos explícitos como Apriori.
- Comprime la base de transacciones en un árbol de patrones frecuentes: **FP-tree**.
- Explora bases condicionales para extraer itemsets frecuentes.

Ventaja

Puede ser mucho más rápido que Apriori en bases grandes o densas, porque reduce pasadas por los datos y evita una explosión de candidatos.

Consideración

La implementación y la estructura de memoria son más complejas que en Apriori.

Comparación conceptual

Algoritmo	Representación	Estrategia	Fortalezas
Apriori	Horizontal	Genera y poda candidatos	Simple, interpretable, clásico
Eclat	Vertical	Intersección de tidsets	Eficiente para ciertos datos dispersos
FP-Growth	Árbol comprimido	Crecimiento de patrones	Rápido en bases grandes/densas

Dataset común para cálculo manual

Usaremos el mismo ejemplo para ilustrar los tres algoritmos clásicos.

ID	Ítems
T1	pan, leche, huevos
T2	pan, mantequilla
T3	leche, huevos, cereal
T4	pan, leche, mantequilla
T5	pan, leche, huevos, mantequilla

Umbral de trabajo

$$N = 5, \quad s_{min} = 0,40$$

$$\text{soporte mínimo en conteo} = 0,40 \times 5 = 2$$

Un itemset es frecuente si aparece en al menos 2 transacciones.

Cálculo manual: dataset y umbral

Base transaccional D

ID	Compra
T1	pan, leche, huevos
T2	pan, mantequilla
T3	leche, huevos, cereal
T4	pan, leche, mantequilla
T5	pan, leche, huevos, mantequilla

Parámetros para todos los algoritmos

$$N = 5, \quad s_{min} = 0,40$$

$$\text{conteo mínimo} = s_{min} \times N = 0,40 \times 5 = 2$$

Regla de decisión

Un itemset se considera frecuente si aparece en **2 o más** transacciones.

Apriori a mano I: contar C_1 y obtener L_1

Idea del algoritmo: primero contar ítems individuales. Luego solo se combinan los ítems frecuentes.

Ítem	Conteo	Soporte
pan	4	$4/5 = 0,80$
leche	4	$4/5 = 0,80$
huevos	3	$3/5 = 0,60$
mantequilla	3	$3/5 = 0,60$
cereal	1	$1/5 = 0,20$

Aplicando soporte mínimo

$$L_1 = \{pan, leche, huevos, mantequilla\}$$

$$cereal \notin L_1 \quad \text{porque} \quad 1 < 2$$

Poda Apriori

Como cereal no es frecuente, ningún itemset que contenga cereal puede ser frecuente.

Apriori a mano II: generar C_2 y obtener L_2

Desde L_1 se generan candidatos de tamaño 2. Luego se cuentan en las 5 transacciones.

Candidato C_2	Conteo	Soporte	Decisión
{pan, leche}	3	$3/5 = 0,60$	frecuente
{pan, huevos}	2	$2/5 = 0,40$	frecuente
{pan, mantequilla}	3	$3/5 = 0,60$	frecuente
{leche, huevos}	3	$3/5 = 0,60$	frecuente
{leche, mantequilla}	2	$2/5 = 0,40$	frecuente
{huevos, mantequilla}	1	$1/5 = 0,20$	se poda

$$L_2 = \{\{pan, leche\}, \{pan, huevos\}, \{pan, mantequilla\}, \{leche, huevos\}, \{leche, mantequilla\}\}$$

Apriori a mano III: generar C_3 , podar y calcular reglas

Candidatos de tamaño 3

Candidato C_3	Conteo	Decisión
{pan, leche, huevos}	2	queda
{pan, leche, mantequilla}	2	queda
{pan, huevos, mantequilla}	–	se poda
{leche, huevos, mantequilla}	–	se poda

Los dos últimos se podan porque contienen:

$$\{\text{huevos, mantequilla}\} \notin L_2$$

Ejemplo de regla desde L_3

$$\{\text{pan, huevos}\} \Rightarrow \{\text{leche}\}$$

$$\text{support} = \frac{\#(\text{pan, huevos, leche})}{5} = \frac{2}{5} = 0,40$$

$$\text{confidence} = \frac{\#(\text{pan, huevos, leche})}{\#(\text{pan, huevos})} = \frac{2}{2} = 1,00$$

$$\text{lift} = \frac{1,00}{\text{support}(\text{leche})} = \frac{1,00}{4/5} = 1,25$$

Eclat a mano I: convertir a formato vertical

Idea del algoritmo: cada ítem guarda el conjunto de transacciones en que aparece.

Ítem	TIDset	Conteo	Decisión
pan	{T1,T2,T4,T5}	4	frecuente
leche	{T1,T3,T4,T5}	4	frecuente
huevos	{T1,T3,T5}	3	frecuente
mantequilla	{T2,T4,T5}	3	frecuente
cereal	{T3}	1	se elimina

$$L_1 = \{pan, leche, huevos, mantequilla\}$$

Diferencia clave con Apriori

Eclat calcula soportes mediante **intersecciones de TIDsets**, no generando y recontando todos los candidatos sobre la tabla original.

Eclat a mano II: intersecciones para obtener itemsets frecuentes

Pares frecuentes

$$T(\text{pan}) \cap T(\text{leche}) = \{T1, T4, T5\} \Rightarrow 3$$

$$T(\text{pan}) \cap T(\text{huevos}) = \{T1, T5\} \Rightarrow 2$$

$$T(\text{pan}) \cap T(\text{mantequilla}) = \{T2, T4, T5\} \Rightarrow 3$$

$$T(\text{leche}) \cap T(\text{huevos}) = \{T1, T3, T5\} \Rightarrow 3$$

$$T(\text{leche}) \cap T(\text{mantequilla}) = \{T4, T5\} \Rightarrow 2$$

$$T(\text{huevos}) \cap T(\text{mantequilla}) = \{T5\} \Rightarrow 1$$

$\{\text{huevos}, \text{mantequilla}\}$ se elimina

Triples por intersección

$$\begin{aligned} T(\text{pan}, \text{leche}) \cap T(\text{huevos}) &= \{T1, T4, T5\} \cap \{T1, T3, T5\} \\ &= \{T1, T5\} \Rightarrow 2 \end{aligned}$$

$\{\text{pan}, \text{leche}, \text{huevos}\}$ es frecuente

$$\begin{aligned} T(\text{pan}, \text{leche}) \cap T(\text{mantequilla}) &= \{T1, T4, T5\} \cap \{T2, T4, T5\} \\ &= \{T4, T5\} \Rightarrow 2 \end{aligned}$$

$\{\text{pan}, \text{leche}, \text{mantequilla}\}$ es frecuente

FP-Growth a mano I: ordenar transacciones frecuentes

Idea del algoritmo: comprimir la base en un FP-tree. Primero se eliminan ítems no frecuentes y se ordenan por frecuencia global.

Ítem	Conteo	Orden
pan	4	1
leche	4	2
huevos	3	3
mantequilla	3	4
cereal	1	eliminado

ID	Original	Ordenada sin cereal
T1	pan, leche, huevos	pan, leche, huevos
T2	pan, mantequilla	pan, mantequilla
T3	leche, huevos, cereal	leche, huevos
T4	pan, leche, mantequilla	pan, leche, mantequilla
T5	pan, leche, huevos, mantequilla	pan, leche, huevos, mantequilla

FP-Growth a mano II: construir el FP-tree

Inserción resumida

- 1 T1 crea la ruta pan-leche-huevos.
- 2 T2 comparte pan y agrega mantequilla bajo pan.
- 3 T3 crea una ruta nueva leche-huevos desde la raíz.
- 4 T4 comparte pan-leche y agrega mantequilla.
- 5 T5 comparte pan-leche-huevos y agrega mantequilla.

FP-tree resultante

```
raiz
|- pan:4
|  |- leche:3
|  |  |- huevos:2
|  |  |  '- mantequilla:1
|  |  '- mantequilla:1
|  '- mantequilla:1
'- leche:1
   '- huevos:1
```

FP-Growth a mano III: bases condicionales y patrones

Sufijo: mantequilla

Prefijo condicional	Conteo
pan	1
pan, leche	1
pan, leche, huevos	1

Conteos condicionales:

$$pan = 3, \quad leche = 2, \quad huevos = 1$$

Patrones frecuentes:

$$\{pan, mantequilla\} : 3, \quad \{leche, mantequilla\} : 2$$

$$\{pan, leche, mantequilla\} : 2$$

Sufijo: huevos

Prefijo condicional	Conteo
pan, leche	2
leche	1

Conteos condicionales:

$$leche = 3, \quad pan = 2$$

Patrones frecuentes:

$$\{leche, huevos\} : 3, \quad \{pan, huevos\} : 2$$

$$\{pan, leche, huevos\} : 2$$

Resultado manual común de los tres algoritmos

Itemset frecuente	Conteo	Soporte
{pan}, {leche}	4	0.80
{huevos}, {mantequilla}	3	0.60
{pan, leche}	3	0.60
{pan, huevos}	2	0.40
{pan, mantequilla}	3	0.60
{leche, huevos}	3	0.60
{leche, mantequilla}	2	0.40
{pan, leche, huevos}	2	0.40
{pan, leche, mantequilla}	2	0.40

Conclusión

Apriori, Eclat y FP-Growth recorren el espacio de búsqueda de forma distinta, pero con el mismo soporte mínimo recuperan los mismos itemsets frecuentes.

R: paquetes necesarios

```
# Instalar una vez
install.packages("arules")
install.packages("arulesViz")
install.packages("tidyverse")

# Cargar en cada sesion
library(arules)
library(arulesViz)
library(tidyverse)
```

Paquete central

arules implementa estructuras de transacciones, Apriori, Eclat y funciones para inspeccionar reglas.

R: cargar datos Groceries

```
library(arules)
data("Groceries")

Groceries
summary(Groceries)
itemFrequency(Groceries)[1:10]
```

- Groceries es un dataset transaccional clásico incluido en arules.
- Cada transacción corresponde a una compra.
- Cada ítem corresponde a un producto comprado.

R: explorar frecuencia de ítems

```
# Frecuencia relativa de items
freq <- itemFrequency(Groceries, type = "relative")
head(sort(freq, decreasing = TRUE), 10)

# Grafico de los 20 items mas frecuentes
itemFrequencyPlot(
  Groceries,
  topN = 20,
  type = "relative",
  main = "Items mas frecuentes"
)
```

Interpretación

Antes de generar reglas conviene revisar cuáles ítems dominan el dataset, porque pueden producir reglas triviales.

R: generar reglas con Apriori

```
rules <- apriori(  
  Groceries,  
  parameter = list(  
    supp = 0.01,  
    conf = 0.30,  
    minlen = 2  
  )  
)  
  
rules  
summary(rules)  
inspect(head(rules, 10))
```

- `supp = 0.01`: la regla debe aparecer en al menos 1 % de las compras.
- `conf = 0.30`: al menos 30 % de confianza.
- `minlen = 2`: antecedente y consecuente no vacíos.

Selección responsable de reglas

- 1 Definir umbrales razonables de soporte y confianza.
- 2 Priorizar reglas con lift alto, pero no extremadamente raras.
- 3 Eliminar reglas redundantes o triviales.
- 4 Validar reglas en datos independientes, cuando sea posible.
- 5 Incorporar conocimiento del dominio antes de concluir causalidad o acción.

Recordar

Las reglas de asociación descubren patrones, no prueban causalidad.

Limitaciones frecuentes

- Explosión combinatoria cuando hay muchos ítems y soporte bajo.
- Reglas triviales por ítems muy frecuentes.
- Sensibilidad a la discretización de variables continuas.
- Dificultad para interpretar miles de reglas simultáneamente.
- No modela ajuste por confusores de forma directa.
- Riesgo de sobreinterpretar correlaciones como causalidad.

- Reglas secuenciales: consideran orden temporal de eventos.
- Reglas ponderadas: algunos ítems tienen mayor importancia o valor.
- Reglas cuantitativas: incorporan variables numéricas discretizadas.
- Reglas negativas: identifican ausencia conjunta o exclusión.
- Reglas de clasificación: consecuente restringido a una clase objetivo.

Ejemplo aplicado

En salud, se puede restringir el consecuente a “respuesta a tratamiento” y buscar combinaciones de biomarcadores asociadas a respuesta o no respuesta.

Ejercicio 1: canasta de compras

- 1 Cargue el dataset Groceries.
- 2 Explore los 20 ítems más frecuentes.
- 3 Genere reglas con $\text{supp} = 0.005$ y $\text{conf} = 0.25$.
- 4 Ordene por lift y seleccione 10 reglas interpretables.
- 5 Elimine reglas redundantes.
- 6 Discuta cuál regla sería útil para una estrategia comercial.

- El análisis de asociación busca relaciones frecuentes del tipo $X \Rightarrow Y$.
- Soporte, confianza y lift responden preguntas distintas.
- Apriori usa poda antimonótona; Eclat usa formato vertical; FP-Growth usa un árbol comprimido.
- En R, `arules` permite generar, filtrar, ordenar y visualizar reglas.
- La interpretación debe considerar redundancia, frecuencia basal, estabilidad y conocimiento del dominio.

- Agrawal, R. y Srikant, R. (1994). Fast algorithms for mining association rules.
- Han, J., Pei, J. y Yin, Y. (2000). Mining frequent patterns without candidate generation.
- Hahsler, M., Grün, B. y Hornik, K. (2005). `arules`: Mining association rules and frequent itemsets.
- Hahsler, M. (2017). `arulesViz`: Interactive visualization of association rules.