

Análisis de asociación II

Filtrado de reglas, visualización e interpretación con R


Minería de Datos

Universidad de O'Higgins

Objetivos de la clase

- 1 Entender por qué Apriori puede generar miles de reglas y cómo reducirlas.
- 2 Filtrar reglas con métricas objetivas, plantillas y redundancia.
- 3 Visualizar reglas con `arulesViz`: scatterplot, matriz, grafo y explorador interactivo.
- 4 Interpretar reglas sin confundir la correlación, la causalidad y los artefactos de soporte bajo.
- 5 Introducir la discretización, las jerarquías de ítems y el análisis multinivel.
- 6 Ejemplos con dataset Zoo

Flujo de análisis recomendado



Idea clave: no se reportan “todas” las reglas; se construye un conjunto pequeño, robusto e interpretable.

El problema: explosión de reglas

Qué ocurre en la práctica

Un umbral de soporte bajo y confianza alta puede generar miles de reglas, muchas redundantes o demasiado específicas.

Ejemplo típico

- Groceries: 9835 transacciones y 169 categorías de producto.
- Con soporte bajo aparecen patrones raros, algunos interesantes y otros espurios.
- El objetivo es pasar de “muchas reglas” a “pocas reglas accionables”.

Medidas básicas y avanzadas

Para una regla $X \Rightarrow Y$:

$$\text{soporte} = P(X \cap Y)$$

$$\text{cobertura} = P(X)$$

$$\text{confianza} = P(Y | X) = \frac{P(X \cap Y)}{P(X)}$$

$$\text{lift} = \frac{P(X \cap Y)}{P(X)P(Y)} = \frac{\text{confianza}}{P(Y)}$$

$$\text{leverage} = P(X \cap Y) - P(X)P(Y)$$

$$\text{conviction} = \frac{1 - P(Y)}{1 - \text{confianza}}$$

Métrica	Interpretación práctica
Soporte	Prevalencia de la regla. Reglas con soporte muy bajo pueden ser inestables.
Confianza	Proporción de transacciones con X que también tienen Y . Puede ser engañosa si Y es muy frecuente.
Lift	Compara la co-ocurrencia observada contra independencia. $\text{Lift} > 1$ sugiere asociación positiva.
Leverage	Diferencia absoluta entre lo observado y lo esperado por independencia. Útil para priorizar impacto.
Conviction	Penaliza contraejemplos de la regla. Crece cuando X rara vez aparece sin Y .
Count	Número absoluto de transacciones. Siempre revisar junto con soporte.

1. Minar reglas con parámetros iniciales

```
rules <- apriori(  
  Groceries,  
  parameter = list(  
    support = 0.005,  
    confidence = 0.3,  
    minlen = 2,  
    maxlen = 5  
  )  
)  
  
rules  
summary(rules)  
inspect(head(sort(rules, by = "lift"), 10))
```

- support: controla prevalencia mínima.
- confidence: controla precisión condicional mínima.
- minlen/maxlen: evita reglas demasiado simples o demasiado específicas.

2. Agregar medidas de interés

```
quality(rules) <- cbind(  
  quality(rules),  
  interestMeasure(  
    rules,  
    measure = c("leverage", "conviction", "phi", "chiSquared"),  
    transactions = Groceries  
  )  
)  
  
head(quality(rules))
```

Uso práctico

Ordenar solo por lift puede sobrerrepresentar reglas raras. Combinar lift con soporte, count, leverage o significancia estadística.

3. Filtrado por calidad

```
rules_q <- subset(  
  rules,  
  subset = support >= 0.01 &  
    confidence >= 0.5 &  
    lift >= 1.5 &  
    count >= 50  
)  
  
rules_q <- sort(rules_q, by = "lift", decreasing = TRUE)  
inspect(head(rules_q, 10))
```

Criterio defendible

“Reportamos reglas con soporte $\geq 1\%$, confianza $\geq 50\%$, lift $\geq 1,5$ y al menos 50 transacciones.”

4. Filtrado por plantillas: RHS específico

```
rules_milk <- apriori(  
  Groceries,  
  parameter = list(support = 0.005, confidence = 0.3, minlen = 2),  
  appearance = list(  
    rhs = "whole milk",  
    default = "lhs"  
  )  
)  
  
rules_milk <- sort(rules_milk, by = "lift")  
inspect(head(rules_milk, 10))
```

Interpretación

Útil cuando el objetivo es explicar un producto, clase o evento específico: “qué antecedentes predicen leche entera”.

5. Filtrado por ítems obligatorios o no deseados

```
# Reglas que contienen yogurt en algún lado
rules_yogurt <- subset(rules, items %in% "yogurt")

# Reglas con yogurt en el antecedente y lift alto
rules_yogurt_lhs <- subset(
  rules,
  subset = lhs %in% "yogurt" & lift > 1.5
)

# Reglas que NO contienen soda
rules_no_soda <- subset(rules, !(items %in% "soda"))
```

- `items %in%`: busca en antecedente o consecuente.
- `lhs %in%`: restringe el antecedente.
- `rhs %in%`: restringe el consecuente.

6. Eliminar reglas redundantes

```
length(rules_q)

redundantes <- is.redundant(rules_q)
table(redundantes)

rules_nr <- rules_q[!redundantes]
rules_nr <- sort(rules_nr, by = "lift")

length(rules_nr)
inspect(head(rules_nr, 10))
```

Definición práctica

Una regla es redundante si existe una regla más general con igual o mayor confianza.

Ejemplo conceptual de redundancia

$\{pan\} \Rightarrow \{leche\}, \quad conf = 0,75$

$\{pan, mantequilla\} \Rightarrow \{leche\}, \quad conf = 0,75$

La segunda regla agrega una condición, pero no mejora la confianza.

Conclusión

Preferir la regla más simple:

$\{pan\} \Rightarrow \{leche\}$

si su desempeño es igual o mejor.

7. Reglas compactas: itemsets cerrados y maximales

```
itemsets <- apriori(
  Groceries,
  parameter = list(support = 0.01, target = "frequent itemsets")
)

closed_itemsets <- itemsets[is.closed(itemsets)]
max_itemsets    <- itemsets[is.maximal(itemsets)]
#vector con comparacin de items
c(
  frequent = length(itemsets),
  closed   = length(closed_itemsets),
  maximal  = length(max_itemsets)
)
```

- **Cerrados:** conservan información de soporte con menos itemsets.
- **Maximales:** resumen aún más, pero pierden soportes de subconjuntos.

8. Prueba estadística para una regla

```
# Ejemplo: yogurt => whole milk
M <- as(Groceries, "matrix")
X <- M[, "yogurt"]
Y <- M[, "whole milk"]

tab <- table(X, Y)
tab

fisher.test(tab)
chisq.test(tab)
```

Uso práctico

La prueba ayuda a evaluar si la co-ocurrencia difiere de independencia, pero no reemplaza la interpretación ni corrige automáticamente por múltiples pruebas.

Queremos entender qué hace este código:

```
# Ejemplo: yogurt => whole milk
M <- as(Groceries, "matrix")
X <- M[, "yogurt"]
Y <- M[, "whole milk"]
tab <- table(X, Y)
tab
fisher.test(tab)
chisq.test(tab)
```

La pregunta estadística es:

¿La compra de yogurt está asociada con la compra de leche entera?

La regla es:

yogurt $\Rightarrow$ whole milk

Interpretación :

Si una transacción contiene yogurt, entonces es más probable que también contenga whole milk.

Pero esta afirmación debe evaluarse con dos criterios:

- 1 **Magnitud de la asociación:** soporte, confianza, lift.
- 2 **Evidencia estadística:** test de independencia.

Paso 1: convertir transacciones a matriz binaria

```
M <- as(Groceries, "matrix")
```

Groceries es un conjunto de transacciones. Cada fila es una compra y cada columna es un producto.

Después de convertirlo a matriz:

$$M_{ij} = \begin{cases} \text{TRUE}, & \text{si la transacción } i \text{ contiene el producto } j \\ \text{FALSE}, & \text{si no lo contiene} \end{cases}$$

Ejemplo conceptual:

Transacción	yogurt	whole milk	bread
T1	TRUE	TRUE	FALSE
T2	FALSE	TRUE	TRUE
T3	TRUE	FALSE	TRUE

Paso 2: definir antecedente y consecuente

```
X <- M[, "yogurt"]  
Y <- M[, "whole milk"]
```

$$X = \text{yogurt}$$
$$Y = \text{whole milk}$$

Cada variable es un vector lógico:

- $X = \text{TRUE}$: la transacción contiene yogurt.
- $Y = \text{TRUE}$: la transacción contiene leche entera.

Por lo tanto, el código transforma una regla en un problema clásico de asociación entre dos variables binarias.

Paso 3: construir la tabla de contingencia

```
tab <- table(X, Y)
tab
```

Salida para Groceries:

	Y = FALSE	Y = TRUE
X = FALSE	6501	1962
X = TRUE	821	551

Donde:

- 551 compras contienen yogurt y whole milk.
- 821 contienen yogurt, pero no whole milk.
- 1962 contienen whole milk, pero no yogurt.
- 6501 no contienen ninguno de los dos productos.

Tabla observada: notación estadística

	$Y = 0$	$Y = 1$	Total
$X = 0$	$d = 6501$	$c = 1962$	8463
$X = 1$	$b = 821$	$a = 551$	1372
Total	7322	2513	9835

Para la regla:

$$X \Rightarrow Y$$

el conteo más importante es:

$$a = \#(X = 1, Y = 1) = 551$$

porque corresponde a las transacciones que contienen ambos productos.

Métricas de la regla

Con los conteos anteriores:

$$N = 9835, \quad a = 551, \quad b = 821, \quad c = 1962, \quad d = 6501$$

$$\text{soporte}(X \Rightarrow Y) = P(X, Y) = \frac{551}{9835} = 0,056$$

$$\text{confianza}(X \Rightarrow Y) = P(Y | X) = \frac{551}{551 + 821} = 0,402$$

$$\text{soporte}(Y) = P(Y) = \frac{2513}{9835} = 0,256$$

$$\text{lift}(X \Rightarrow Y) = \frac{P(Y | X)}{P(Y)} = \frac{0,402}{0,256} = 1,57$$

Interpretación: entre quienes compran yogurt, la probabilidad de comprar leche entera es 1.57 veces la probabilidad basal de comprar leche entera.

¿Por qué hacer un test estadístico?

Las métricas describen la asociación, pero no responden completamente:

¿La co-ocurrencia observada podría explicarse por azar?

Para eso se testea independencia:

$$H_0 : X \text{ e } Y \text{ son independientes}$$

$$H_1 : X \text{ e } Y \text{ no son independientes}$$

En términos de la regla:

$$H_0 : P(Y | X) = P(Y)$$

$$H_1 : P(Y | X) \neq P(Y)$$

Conteos esperados bajo independencia

Si yogurt y whole milk fueran independientes, el conteo esperado en cada celda sería:

$$E_{ij} = \frac{(\text{total fila } i)(\text{total columna } j)}{N}$$

	Y = FALSE	Y = TRUE
X = FALSE	6300.57	2162.43
X = TRUE	1021.43	350.57

Celda clave:

$$E(X = 1, Y = 1) = 350,57$$

Pero observamos:

$$O(X = 1, Y = 1) = 551$$

Hay muchas más compras conjuntas de yogurt y whole milk de las esperadas bajo independencia.

Test chi-cuadrado de independencia

```
chisq.test(tab)
```

El test compara conteos observados contra conteos esperados:

$$\chi^2 = \sum \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

```
Pearson's Chi-squared test with Yates' continuity correction
```

```
X-squared = 177.99, df = 1, p-value < 2.2e-16
```

Interpretación: el valor-p es extremadamente pequeño, por lo tanto se rechaza la independencia entre yogurt y whole milk.

Test exacto de Fisher

```
fisher.test(tab)
```

El test exacto de Fisher también evalúa independencia en una tabla 2×2 .

Es especialmente útil cuando hay conteos pequeños. En este ejemplo los conteos son grandes, pero Fisher sigue siendo válido.

```
Fisher's Exact Test for Count Data
```

```
p-value < 2.2e-16  
alternative hypothesis: true odds ratio is not equal to 1  
sample estimates:  
odds ratio = 2.22
```

Interpretación: las odds de comprar whole milk son mayores entre quienes compran yogurt.

Odds ratio y asociación positiva

El odds ratio de la tabla es:

$$OR = \frac{a \cdot d}{b \cdot c}$$

$$OR = \frac{551 \times 6501}{821 \times 1962} = 2,22$$

Interpretación:

- $OR = 1$: no hay asociación.
- $OR > 1$: asociación positiva.
- $OR < 1$: asociación negativa.

En este caso:

$$OR = 2,22 > 1$$

lo que apoya una asociación positiva entre yogurt y whole milk.

La regla yogurt $\Rightarrow$ whole milk muestra una asociación positiva y estadísticamente significativa en el dataset Groceries.

Test direccional: asociación positiva

Por defecto, Fisher testea si existe asociación en cualquier dirección:

$$H_1 : OR \neq 1$$

Pero si queremos testear específicamente una regla positiva:

yogurt $\Rightarrow$ whole milk

podemos usar:

```
fisher.test(tab, alternative = "greater")
```

Esto evalúa:

$$H_1 : OR > 1$$

Es decir, si yogurt y whole milk aparecen juntos más de lo esperado bajo independencia.

El test demuestra asociación, no causalidad.

No podemos concluir:

Comprar yogurt causa comprar leche entera.

Sí podemos concluir:

En estas transacciones, yogurt y leche entera aparecen juntos más de lo esperado bajo independencia.

Además, en minería de reglas se prueban muchas asociaciones; por lo tanto, en análisis formales conviene considerar ajuste por múltiples pruebas o usar el test como herramienta interpretativa secundaria.

9. Barrido de parámetros

```
grid <- expand.grid(
  support = c(0.001, 0.005, 0.01, 0.02),
  confidence = c(0.3, 0.5, 0.7)
)

grid$n_rules <- purrr::map2_int(
  grid$support, grid$confidence,
  ~ length(apriori(
    Groceries,
    parameter = list(support = .x, confidence = .y, minlen = 2),
    control = list(verbose = FALSE)
  ))
)

grid
```

Visualizar sensibilidad de parámetros

```
ggplot(grid, aes(x = support, y = n_rules, color = factor(confidence))) +  
  geom_line() +  
  geom_point() +  
  scale_x_log10() +  
  labs(  
    x = "Soporte minimo",  
    y = "Numero de reglas",  
    color = "Confianza"  
  ) +  
  theme_minimal()
```

Lectura


Una caída abrupta indica que el umbral de soporte está controlando fuertemente el espacio de búsqueda.

Visualizacion 1: frecuencia de items

```
itemFrequencyPlot(trans, topN = 20)
```

Que mirar

- Items muy frecuentes: potenciales reglas triviales.
- Items raros: requieren soporte bajo.
- Variables de clase: `type=...`




Visualizacion 2: scatterplot de reglas

```
plot(rules)
plot(rules, shading = "order")
plot(rules, control = list(jitter = 0))
```

Como leerlo

- X: soporte.
- Y: confianza.
- Color: lift u orden de la regla.
- Nubes densas indican reglas repetitivas.




Visualizacion 3: matriz agrupada

```
set.seed(1234)
plot(rules,
      method = "grouped matrix")
```

Como leerla

Agrupar reglas con relaciones LHS-RHS similares. Es útil cuando hay muchas reglas, porque revela bloques: peces, aves, mamíferos.

Grupo de reglas	RHS dominante	Rasgos frecuentes	Int
G1	type=fish	eggs, fins, aquatic	Pe
G2	type=bird	feathers, airborne, tail	Pe
G3	type=mammal	milk, hair, toothed	Per




Visualizacion 4: grafo de reglas

```
plot(rules, method = "graph")
```

```
plot(head(rules, by = "phi", n = 100),  
     method = "graph")
```

Cuando usarlo

Usar pocos nodos: top 50 o top 100 por lift, phi o confianza. Si se grafican miles de reglas, el grafo deja de ser interpretable.



Errores frecuentes de interpretación

- ❶ **Confundir confianza con causalidad:** $X \Rightarrow Y$ no significa que X cause Y .
- ❷ **Ignorar la frecuencia base de Y :** si Y es muy común, la confianza puede ser alta sin asociación real.
- ❸ **Sobrevalorar lift con soporte bajo:** una regla rara puede tener lift extremo por azar.
- ❹ **No revisar conteos absolutos:** soporte relativo sin count puede ocultar inestabilidad.
- ❺ **Reportar reglas redundantes:** reglas más largas no siempre son mejores.

Regla

$\{yogurt, other\ vegetables\} \Rightarrow \{whole\ milk\}$

- 1 **Cobertura:** qué proporción compra yogurt y verduras.
- 2 **Confianza:** entre quienes compran eso, cuántos también compran leche.
- 3 **Lift:** cuánto aumenta la probabilidad respecto a comprar leche al azar.
- 4 **Count:** cuántas transacciones reales apoyan la regla.
- 5 **Acción:** promoción cruzada, layout, recomendador o hipótesis de comportamiento.

Variables categóricas, lógicas y continuas

- Variables categóricas: cada nivel se transforma en un ítem, por ejemplo Species=setosa.
- Variables lógicas: normalmente solo TRUE genera un ítem.
- Variables continuas: deben discretizarse antes de transformarse en ítems.

Riesgo metodológico

La discretización cambia las reglas encontradas. Debe justificarse y, si es posible, evaluarse con sensibilidad.

Ejemplo: discretización con iris

```
data(iris)
iris$Versicolor <- iris$Species == "versicolor"

iris_disc <- iris %>%
  mutate(
    Petal.Length = discretize(Petal.Length,
                              method = "frequency",
                              breaks = 3,
                              labels = c("short", "medium", "long")),
    Petal.Width = discretize(Petal.Width,
                              method = "frequency",
                              breaks = 2,
                              labels = c("narrow", "wide"))
  )

iris_trans <- transactions(iris_disc)
itemLabels(iris_trans)
```

Reglas de asociación orientadas a clase

```
iris_rules <- apriori(  
  iris_trans,  
  parameter = list(support = 0.05, confidence = 0.8, minlen = 2),  
  appearance = list(  
    rhs = c("Species=setosa", "Species=versicolor", "Species=virginica"),  
    default = "lhs"  
  )  
)  
  
iris_rules <- iris_rules[!is.redundant(iris_rules)]  
inspect(sort(iris_rules, by = "lift"))
```

Uso

Puede verse como un clasificador interpretable basado en reglas.

Ejemplo supermercado

- whole milk, yogurt, cream → dairy produce
- citrus fruit, tropical fruit → fruit

Ventaja

Permite descubrir reglas a nivel de producto, categoría o ambos niveles simultáneamente.

Agregación de ítems en Groceries

```
data("Groceries")
head(itemInfo(Groceries))

Groceries_level2 <- aggregate(Groceries, by = "level2")
Groceries_level2

inspect(head(Groceries, 3))
inspect(head(Groceries_level2, 3))

rules_level2 <- apriori(
  Groceries_level2,
  parameter = list(support = 0.005, confidence = 0.8)
)
inspect(head(sort(rules_level2, by = "lift"), 10))
```

Análisis multinivel

```
Groceries_multi <- addAggregate(Groceries, "level2")
inspect(head(Groceries_multi, 3))

rules_multi <- apriori(
  Groceries_multi,
  parameter = list(support = 0.005, confidence = 0.8)
)

# Elimina reglas espurias: item A => grupo de item A
rules_multi <- filterAggregate(rules_multi)
inspect(head(sort(rules_multi, by = "lift"), 10))
```

Interpretación

Ayuda a estudiar si la asociación ocurre entre productos concretos o entre categorías generales.

Dataset Zoo: animales como transacciones

```
library(arules)
library(arulesViz)
library(mlbench)
library(tidyverse)

data(Zoo, package = "mlbench")

Zoo_has_legs <- Zoo |>
  mutate(legs = legs > 0)

trans <- transactions(Zoo_has_legs)
trans
```

transactions in sparse format with
101 transactions (rows)
23 items (columns)

Interpretacion

Cada animal es una transaccion. Cada rasgo es un item: hair, milk, fins, type=mammal, etc.

Antes de minar reglas: inspeccionar las transacciones

```
summary(trans)
itemFrequencyPlot(trans, topN = 20)
inspect(trans[1:3])
```

```
most frequent items:
backbone breathes legs tail toothed
      83      80    78   75      61
```

```
itemset length:
Min. 3 | Median 9 | Mean 8.31
Max. 12
```

Recordar

Si los items frecuentes son muy generales, muchas reglas tendran alta confianza pero baja utilidad interpretativa.

El problema: demasiadas reglas


```
rules <- apriori(  
  trans,  
  parameter = list(  
    support = 0.05,  
    confidence = 0.9  
  )  
)  
length(rules)
```

```
Absolute minimum support count: 5  
set transactions ...  
  [23 item(s), 101 transaction(s)]  
checking subsets of size 1 2 ... 10  
writing ... [7174 rule(s)]  
  
[1] 7174
```

Pregunta

¿Cómo pasamos de 7174 reglas a un conjunto que se pueda explicar en clase o en un informe?

Mapa general de mecanismos de filtrado



Idea central

El filtrado debe combinar criterios estadísticos, criterios computacionales y criterios de interpretación del problema.

Filtro 1: soporte minimo

Definicion

$$\text{supp}(X \Rightarrow Y) = \frac{\#\{t : X \cup Y \subseteq t\}}{N}$$

```
# soporte para al menos 5 animales
5 / nrow(trans)

its_10 <- apriori(trans,
  parameter = list(target = "frequent",
    support = 0.10))

its_05 <- apriori(trans,
  parameter = list(target = "frequent",
    support = 0.05))
```

```
[1] 0.0495
```

```
support = 0.10 -> 1465 itemsets
support = 0.05 -> 2537 itemsets
```

Interpretacion

Bajar soporte de 10 % a 5 % permite detectar patrones que aparecen en al menos 5 animales, pero aumenta mucho el espacio de búsqueda.

Resultado del soporte: itemsets frecuentes principales

```
its <- sort(its_05, by = "support")  
inspect(head(its, n = 10))
```

Itemset	support	count
{backbone}	0.8218	83
{breathes}	0.7921	80
{legs}	0.7723	78
{tail}	0.7426	75
{backbone, tail}	0.7327	74
{breathes, legs}	0.7228	73
{backbone, breathes}	0.6832	69
{backbone, legs}	0.6337	64
{backbone, breathes, legs}	0.6337	64
{toothed}	0.6040	61

Lectura

Los itemsets mas frecuentes describen rasgos generales. Son utiles para explorar estructura, pero no necesariamente son las reglas mas informativas.

Filtro 2: confianza minima

Definición

$$\text{conf}(X \Rightarrow Y) = \frac{\text{supp}(X \cup Y)}{\text{supp}(X)} = P(Y | X)$$

```
rules <- apriori(trans,
  parameter = list(
    support = 0.05,
    confidence = 0.9))

inspect(head(rules))
```

LHS	RHS	supp.	conf.	lift
{type=insect}	{eggs}	0.079	1.0	1.712
{type=insect}	{legs}	0.079	1.0	1.295
{type=insect}	{breathes}	0.079	1.0	1.262
{type=mollusc...}	{eggs}	0.089	0.9	1.541
{type=fish}	{fins}	0.129	1.0	5.941
{type=fish}	{aquatic}	0.129	1.0	2.806

Cuidado

Alta confianza no implica relevancia: puede deberse a que el RHS es muy frecuente.

Filtro 3: lift para evitar reglas triviales

Definición

$$\text{lift}(X \Rightarrow Y) = \frac{\text{conf}(X \Rightarrow Y)}{\text{supp}(Y)}$$

```
rules_lift <- sort(rules, by = "lift")  
inspect(head(rules_lift, n = 6))
```

LHS	RHS	supp.	conf.	
{eggs, fins}	{type=fish}	0.1287	1	7.7
{eggs, aquatic, fins}	{type=fish}	0.1287	1	7.7
{eggs, toothed, fins}	{type=fish}	0.1287	1	7.7
{eggs, fins, tail}	{type=fish}	0.1287	1	7.7
{eggs, backbone, fins}	{type=fish}	0.1287	1	7.7
{eggs, aquatic, toothed, fins}	{type=fish}	0.1287	1	7.7

Interpretacion biologica simple

En Zoo, los peces tienen un perfil muy distintivo: fins, eggs y rasgos acuaticos predicen fuertemente type=fish.

Filtro 4: restringir el RHS con appearance

Motivacion

Si el objetivo es interpretar rasgos que predicen el tipo de animal, conviene forzar reglas de la forma:

$$\text{rasgos} \Rightarrow \text{type} = \text{animal}$$

```
type <- grep("type=", itemLabels(trans),  
            value = TRUE)
```

```
type
```

```
rules_type <- apriori(  
  trans,  
  appearance = list(rhs = type)  
)  
rules_type
```

```
[1] "type=mammal" "type=bird"  
[3] "type=reptile" "type=fish"  
[5] "type=amphibian" "type=insect"  
[7] "type=mollusc.et.al"
```

```
writing ... [571 rule(s)]
```

```
set of 571 rules
```

Resultado de appearance: reglas orientadas a clase

```
rules_type |>
  sort(by = "lift") |>
  head() |>
  inspect()
```

LHS	RHS	support	confidence	lift	count
{eggs, fins}	{type=fish}	0.1287	1	7.769	13
{eggs, aquatic, fins}	{type=fish}	0.1287	1	7.769	13
{eggs, toothed, fins}	{type=fish}	0.1287	1	7.769	13
{eggs, fins, tail}	{type=fish}	0.1287	1	7.769	13
{eggs, backbone, fins}	{type=fish}	0.1287	1	7.769	13
{eggs, aquatic, toothed, fins}	{type=fish}	0.1287	1	7.769	13

Interpretación

El filtro por plantilla elimina reglas como `type=fish => fins` y enfoca la pregunta en reglas tipo clasificador: `rasgos => clase`.

Filtro 5: tamaño de la regla

Motivacion

Reglas largas suelen tener alta confianza, pero son difíciles de explicar.

```
table(size(rules_type))  
  
rules_short <- rules_type[  
  size(rules_type) <= 3  
]  
length(rules_short)
```

```
  2   3   4   5   6   7   8   9  10  
3  29  95 155 150  92  37   9   1  
  
# size <= 3  
[1] 32
```

Lectura

`size(rule)` cuenta LHS + RHS. Si RHS tiene un item, `size <= 3` equivale aproximadamente a LHS de maximo 2 items.

Filtro 6: reglas redundantes

Definición operacional

Una regla es redundante si existe una regla mas general con igual o mayor confianza.

Ejemplo:

$\{eggs, fins\} \Rightarrow \{type = fish\}$

$\{eggs, aquatic, fins\} \Rightarrow \{type = fish\}$

Ambas tienen soporte 0.1287 y confianza 1. La segunda agrega aquatic, pero no mejora la regla.

```
rules_nr <- rules_type[
  !is.redundant(rules_type)
]
```

```
rules_type
rules_nr
```


```
set of 571 rules
set of 29 rules
```

Efecto del filtro de redundancia

```
table(size(rules_type))  
table(size(rules_nr))
```

```
# Antes  
2 3 4 5 6 7 8 9 10  
3 29 95 155 150 92 37 9 1
```

```
# Despues  
2 3 4 5  
3 13 10 3
```



Reglas no redundantes: ejemplos interpretables

```
inspect(rules_nr)
```

LHS	RHS	support	confidence	lift	count
{feathers}	{type=bird}	0.1980	1.0000	5.050	20
{milk}	{type=mammal}	0.4059	1.0000	2.463	41
{hair}	{type=mammal}	0.3861	0.9070	2.234	39
{eggs, fins}	{type=fish}	0.1287	1.0000	7.769	13
{fins, tail}	{type=fish}	0.1287	0.8125	6.312	13
{airborne, tail}	{type=bird}	0.1584	0.8889	4.489	16
{airborne, backbone}	{type=bird}	0.1584	0.8889	4.489	16
{hair, catsize}	{type=mammal}	0.2970	1.0000	2.463	30

Recordar

Despues del filtro, las reglas son pocas y semanticas: plumas predicen aves, leche predice mamiferos, huevos+aletas predice peces.

Filtro 7: medidas adicionales con interestMeasure

Por que usar mas metricas?

Soporte, confianza y lift no siempre capturan asociacion simetrica o poder discriminativo. arules permite calcular otras medidas, como phi y gini.

```
quality(rules) <- cbind(  
  quality(rules),  
  interestMeasure(  
    rules,  
    measure = c("phi", "gini"),  
    trans = trans))  
  
rules |>  
  head(by = "phi") |>  
  inspect()
```

LHS	RHS	supp.	conf.	lift
{eggs,fins}	{type=fish}	0.1287	1	7.769
{eggs,aquatic,fins}	{type=fish}	0.1287	1	7.769
{eggs,toothed,fins}	{type=fish}	0.1287	1	7.769

Ejemplo de filtro combinado

```
rules_filtered <- subset(  
  rules,  
  subset = support >= 0.05 &  
    confidence >= 0.9 &  
    lift > 2 &  
    phi > 0.5  
)  
  
rules_filtered <- sort(rules_filtered, by = "lift")  
inspect(head(rules_filtered, n = 10))
```

Interpretacion

Este filtro busca reglas con evidencia minima, alta predictividad, asociacion no trivial y correlacion fuerte entre LHS y RHS.

Recomendacion

No existe un filtro universal. El filtro debe responder a la pregunta de analisis: exploracion, recomendacion, clasificacion o explicacion.

Codificación: incluir items negativos puede explotar las reglas

```
Zoo_factors <- Zoo_has_legs |>  
  mutate(across(where(is.logical), factor))  
  
trans_factors <- transactions(Zoo_factors)  
trans_factors  
  
r_neg <- apriori(trans_factors)  
r_neg  
print(object.size(r_neg), unit = "Mb")
```

```
transactions in sparse format with  
  101 transactions  
   39 items  
  
writing ... [1517191 rule(s)]  
  
set of 1517191 rules  
110.2 Mb
```

Interpretación

Convertir TRUE/FALSE a factores crea items como milk=FALSE, fins=FALSE. Esto puede revelar ausencias informativas, pero también genera muchas reglas obvias.

Ejemplo: reglas con items negativos

```
r_neg |>  
  head(n = 10, by = "lift") |>  
  inspect()
```

LHS	RHS	support	confidence	lift	count
{breathes=FALSE, fins=TRUE}	{type=fish}	0.1287	1	7.769	13
{eggs=TRUE, fins=TRUE}	{type=fish}	0.1287	1	7.769	13
{milk=FALSE, fins=TRUE}	{type=fish}	0.1287	1	7.769	13
{breathes=FALSE, fins=TRUE, legs=FALSE}	{type=fish}	0.1287	1	7.769	13
{aquatic=TRUE, breathes=FALSE, fins=TRUE}	{type=fish}	0.1287	1	7.769	13

Cuando usar items negativos

Usarlos selectivamente cuando la ausencia tenga sentido: por ejemplo, `milk=FALSE` puede ayudar a diferenciar peces de mamiferos, pero incluir todas las ausencias puede saturar el analisis.

Itemsets cerrados y maximales

Motivacion

Antes de mirar reglas, se puede reducir el espacio mirando representaciones compactas de itemsets frecuentes.

```
its <- apriori(trans,  
  parameter = list(target = "frequent",  
                    support = 0.05))
```

```
its_closed <- its[is.closed(its)]  
its_max <- its[is.maximal(its)]
```

```
c(frequent = length(its),  
  closed = length(its_closed),  
  maximal = length(its_max))
```

frequent	closed	maximal
2537	230	22

Lectura

closed conserva soporte exacto. maximal conserva solo patrones mas especificos, pero pierde informacion de soporte de subconjuntos.

Ejemplos de itemsets maximales y cerrados

```
its_max |>  
  head(by = "support") |>  
  inspect()
```

Itemset maximal	count
{hair, milk, predator, toothed, backbone, breathes, legs, tail, catsize, type=mammal}	13
{eggs, aquatic, predator, toothed, backbone, fins, tail, type=fish}	9

Checklist para reportar reglas

- ❶ ¿Cómo se codificaron o discretizaron los datos?
- ❷ ¿Cuáles fueron los umbrales de soporte, confianza y largo de regla?
- ❸ ¿Qué filtros posteriores se aplicaron?
- ❹ ¿Se eliminaron reglas redundantes?
- ❺ ¿Se revisaron conteos absolutos?
- ❻ ¿Se visualizaron patrones globales y no solo reglas individuales?
- ❼ ¿La interpretación evita causalidad no justificada?

- El valor del análisis de asociación no está solo en minar reglas, sino en filtrarlas e interpretarlas.
- Lift, leverage, conviction, count y significancia ayudan a priorizar reglas.
- Las visualizaciones permiten detectar estructura, redundancia y grupos de reglas.
- La discretización y las jerarquías cambian el espacio de patrones disponibles.
- Un buen informe explica el criterio de selección.

- Michael Hahsler. *An R Companion for Introduction to Data Mining*. Capítulo 5: Association Analysis: Basic Concepts.
https://mhahsler.github.io/Introduction_to_Data_Mining_R_Examples/book/association-analysis-basic-concepts.html
- Michael Hahsler. *An R Companion for Introduction to Data Mining*. Capítulo 6: Association Analysis: Advanced Concepts.
https://mhahsler.github.io/Introduction_to_Data_Mining_R_Examples/book/association-analysis-advanced-concepts.html
- Hahsler, M., Grün, B., Hornik, K. (2005). *arules: Mining Association Rules and Frequent Itemsets*.
- Hahsler, M. (2017). *arulesViz: Interactive Visualization of Association Rules with R*.