

Metodós Estadísticos I

Minería de datos

Alex Di Genova

La paradoja de Simpson

- Admisiones en Universidad de California 1973 (postgrado)

	Number of applicants	Percent admitted
Males	8442	44%
Females	4321	35%

13000 aplicaciones y 9% de diferencia en género

Department	Males		Females	
	Applicants	Percent admitted	Applicants	Percent admitted
A	825	62%	108	82%
B	560	63%	25	68%
C	325	37%	593	34%
D	417	33%	375	35%
E	191	28%	393	24%
F	272	6%	341	7%

> % para mujeres?

La paradoja de Simpson


- Admisiones en Universidad de California 1973 (postgrado)

Department	Males		Females	
	Applicants	Percent admitted	Applicants	Percent admitted
A	825	62%	108	82%
B	560	63%	25	68%
C	325	37%	593	34%
D	417	33%	375	35%
E	191	28%	393	24%
F	272	6%	341	7%

1. Los departamentos no tienen los mismos porcentajes de admisión (A es más fácil que F).
2. Hombre y mujeres postulan a departamentos distintos.
 1. Hombres : **A > B > D > C > F > E** “+ fáciles en negrilla” (% admisión altos)
 2. Mujeres: **C > E > D > F > A > B**. (Mujeres tienden a aplicar a departamentos más difíciles)

La paradoja de Simpson

- Admisiones en Universidad de California 1973 (postgrado)



1. Analizar datos es difícil, y hay muchas **trampas sutiles** y **contraintuitivas** esperando por quienes **no están atentos**.
2. Cuando miramos los datos **“agregados”**, parecía que la universidad estaba discriminando a las mujeres; pero cuando **“desagregamos”** los datos y analizamos el comportamiento individual de cada departamento, resultó que los departamentos, en realidad, estaban ligeramente sesgados a favor de las mujeres.
3. La estadística es una **herramienta** que nos ayuda a aprender a partir de nuestros datos.

Un conocimiento básico de estadística está bastante cerca de ser una herramienta de supervivencia!

Diseño de experimentos

Breve introducción

- La recolección de datos puede concebirse como una forma de **medición**.
- **La operacionalización** es el proceso mediante el cual tomamos un concepto significativo, pero algo vago, y lo convertimos en una medición precisa.
- ¿“edad” significa “tiempo desde el nacimiento” o “tiempo desde la concepción”?
- ¿Cómo lo vamos a medir (autorreportada, consulta a familiar, CI)?
- ¿Qué valores puede tomar nuestra variable? (Días, años, meses...)

- Variables **categóricas**
- Variables **continuas y discretas**.
- La **confiabilidad** de una variable te indica con qué precisión mides algo (repetibilidad o consistencia).
- Predictor y outcome

role of the variable	classical name	modern name
“to be explained”	dependent variable (DV)	outcome
“to do the explaining”	independent variable (IV)	predictor

Diseño de experimentos

Determinando la validez de un experimento

- La **validez interna** se refiere al grado en que eres capaz de extraer conclusiones correctas sobre las relaciones causales entre variables.
- La **validez externa** se relaciona con la generalización de tus resultados. Es decir, hasta qué punto esperas observar en la ‘vida real’ el mismo patrón de resultados que viste en tu estudio.
- **Factor de confusión:** es una variable adicional, a menudo no medida, que suele estar relacionada tanto con los predictores como con los resultados.
- **Artefacto:** se dice que un resultado es un artefacto si solo se sostiene en la situación especial de estudio.
- **El sesgo de selección** ocurre cuando los grupos comparados tienen características iniciales diferentes, por ejemplo, un distinto balance de género.
- **El sesgo de no respuesta** ocurre cuando quienes responden a una encuesta no representan de forma aleatoria a la población total, lo que limita la generalización de los resultados.
- **El sesgo del experimentador** ocurre cuando quien realiza el estudio, aun sin intención, influye en los resultados al comunicar sutilmente a los participantes la respuesta o conducta esperada.
- **El efecto placebo** es un tipo de efecto en el que el simple hecho de recibir un tratamiento produce una mejora, incluso si dicho tratamiento no tiene un efecto real.
- **Fraude, engaño y autoengaño**

Estadística descriptiva

- Una de las primeras tareas es encontrar formas de resumirlo de manera compacta y fácil de entender.

- **Medidas de tendencia central**

- Promedio, mediana, moda.
- `mean( x = dataset, trim = .1)`

- **Medidas de variabilidad**

- Rango, min., máx.,
- Rango intercuartil (IQR): la diferencia entre el tercer y el primer cuartil de una distribución.

- **Medidas de variabilidad**

- Varianza, desviación estándar.

- **Medidas de variabilidad**

- Rango, min., máx.,
- Rango intercuartil (IQR): la diferencia entre el tercer y el primer cuartil de una distribución.

```
> summary( object = afl.margins )  
Min.  1st Qu.  Median    Mean 3rd Qu.    Max.   
0.00   12.75   30.50   35.30   50.50  116.00
```

Estadística descriptiva





Correlación

- Relaciones entre variables
- Covarianza

$$\text{Cov}(X, Y) = \frac{1}{N - 1} \sum_{i=1}^N (X_i - \bar{X}) (Y_i - \bar{Y})$$

- “Promedio del producto punto”
- Si X e Y no están relacionadas, la covarianza es 0.

$$r_{XY} = \frac{\text{Cov}(X, Y)}{\hat{\sigma}_X \hat{\sigma}_Y}$$

positive correlations		negative correlations	
correlation	example	correlation	example
0.0		0.0	
0.33		-0.33	
Correlation		Strength	Direction
-1.0 to -0.9		Very strong	Negative
-0.9 to -0.7		Strong	Negative
-0.7 to -0.4		Moderate	Negative
-0.4 to -0.2		Weak	Negative
-0.2 to 0		Negligible	Negative
0 to 0.2		Negligible	Positive
0.2 to 0.4		Weak	Positive
0.4 to 0.7		Moderate	Positive
0.7 to 0.9		Strong	Positive
0.9 to 1.0		Very strong	Positive

Inferencia estadística

Aprender de los datos

- Aprender de los datos sin hacer supuestos es un mito.
- Un test estadístico no responde "si algo es verdad". Responde una pregunta más limitada: si los datos observados son compatibles con una hipótesis nula bajo ciertos supuestos.

Elemento	Pregunta practica
Pregunta cientifica	¿Que diferencia, asociacion o efecto quiero evaluar?
Variable respuesta	¿Es numerica continua, categorica, binaria, conteo u ordinal?
Variable explicativa	¿Define grupos, tratamientos, tiempo, pares o covariables?
Diseño	¿Muestras independientes, pareadas, repetidas u observacionales?
Hipotesis nula H0	Generalmente: no hay diferencia, no hay asociacion o el efecto es cero.
Hipotesis alternativa H1	Generalmente: existe diferencia, asociacion o efecto distinto de cero.

Inferencia estadística

De datos a conclusión

Paso	Accion	Ejemplo en R
1	Explorar datos: dimensiones, NA, distribucion, outliers.	<code>glimpse(df); summary(df); ggplot(df, aes(x, y)) + geom_point()</code>
2	Formular H0 y H1 antes de mirar el p-valor.	H0: <code>media_A = media_B</code> ; H1: <code>media_A != media_B</code>
3	Elegir test segun variable, grupos, independencia y supuestos.	<code>t.test()</code> , <code>wilcox.test()</code> , <code>chisq.test()</code> , <code>fisher.test()</code> , <code>aov()</code>
4	Verificar supuestos o elegir alternativa robusta.	<code>shapiro.test()</code> , <code>car::leveneTest()</code> , plots de residuos
5	Reportar efecto + incertidumbre, no solo p-valor.	mean diff, OR, eta2, r, IC95%
6	Interpretar en lenguaje del problema.	"La diferencia estimada fue...", no solo " $p < 0.05$ ".

Inferencia estadística

Como elegir el test

Variable respuesta	Comparacion / pregunta	Diseño	Test parametrico	Alternativa no parametrica
Numerica	Media vs valor teorico	1 muestra	t-test de una muestra	Wilcoxon signed-rank
Numerica	Media entre 2 grupos	Independientes	t-test independiente	Mann-Whitney / Wilcoxon rank-sum
Numerica	Media antes vs despues	Pareado	t-test pareado	Wilcoxon signed-rank pareado
Numerica	Medias en 3+ grupos	Independientes	ANOVA de una via	Kruskal-Wallis
Numerica	Medidas repetidas 3+ condiciones	Pareado/repetido	ANOVA medidas repetidas	Friedman
Categorica	Asociacion entre 2 variables categoricas	Tabla RxC	Chi-cuadrado	Fisher si conteos pequenos
Binaria	Diferencia de proporciones	2 o mas grupos	prop.test / chi-cuadrado	Fisher / modelos logisticos exactos
Numerica-numerica	Asociacion lineal o monotona	Pares	Pearson	Spearman / Kendall

Regla práctica: si los supuestos son dudosos, muestra pequeña o hay outliers fuertes, considera una alternativa no paramétrica

Inferencia estadística

Como escribir H0 y H1

Caso	H0	H1 bilateral	H1 unilateral
Una media	$\mu = \mu_0$	$\mu \neq \mu_0$	$\mu > \mu_0$ o $\mu < \mu_0$
Dos medias independientes	$\mu_1 = \mu_2$	$\mu_1 \neq \mu_2$	$\mu_1 > \mu_2$ o $\mu_1 < \mu_2$
Datos pareados	$\mu_d = 0$	$\mu_d \neq 0$	$\mu_d > 0$ o $\mu_d < 0$
ANOVA	$\mu_1 = \mu_2 = \dots = \mu_k$	Al menos una media difiere	No aplica habitualmente
Fisher / chi-cuadrado	Las variables son independientes	Existe asociacion	$OR > 1$ u $OR < 1$ en tablas 2x2
Correlacion	$\rho = 0$	$\rho \neq 0$	$\rho > 0$ o $\rho < 0$
Regresion lineal	$\beta_j = 0$	$\beta_j \neq 0$	$\beta_j > 0$ o $\beta_j < 0$

Inferencia estadística

Test-t de una muestra

- ¿La media de una variable numérica difiere de un valor de referencia?

Componente	Descripcion
H0	$\mu = \mu_0$. La media poblacional es igual al valor teorico.
H1	$\mu \neq \mu_0$, o una alternativa direccional.
Supuestos	Observaciones independientes; variable aproximadamente normal o n suficientemente grande.
Ejemplo	¿La media de Sepal.Length en iris difiere de 5.8?

```
data(iris)
```

```
t.test(iris$Sepal.Length, mu = 5.8)
```

```
iris %>%
```

```
summarise(n = n(), media = mean(Sepal.Length), sd = sd(Sepal.Length))
```

Inferencia estadística

Test-t de para dos grupos independientes

- ¿Dos grupos independientes tienen distintas medias? Ejemplo: longitud del sépalo entre dos especies.

Decision	Recomendacion
Varianzas posiblemente distintas	Usar Welch t-test, que es el default de t.test() en R.
Varianzas iguales y diseño balanceado	Student t-test tambien es valido, pero Welch suele ser mas seguro.
Muestra pequena + no normalidad fuerte	Considerar Mann-Whitney/Wilcoxon rank-sum.
Outliers extremos	Revisar datos, graficar, considerar transformacion o test robusto.

```
df <- iris %>% filter(Species %in% c("setosa", "versicolor"))
t.test(Sepal.Length ~ Species, data = df)
effectsize::cohens_d(Sepal.Length ~ Species, data = df)
```

Inferencia estadística

Test-t pareados: antes y después

- ¿La misma unidad experimental cambia entre dos condiciones?
El test se aplica a las diferencias dentro de cada par.

Componente	Descripcion
H0	La media de las diferencias es 0.
H1	La media de las diferencias es distinta de 0.
Ejemplos	Antes/despues de una intervencion; dos mediciones en el mismo individuo; algoritmo A vs B sobre los mismos datasets.
Clave	No compares como si fueran grupos independientes. El pareamiento aumenta potencia y controla variabilidad individual.

```
asset.seed(1)
```

```
antes <- rnorm(20, mean = 50, sd = 8)
```

```
despues <- antes + rnorm(20, mean = 4, sd = 5)
```

```
t.test(despues, antes, paired = TRUE)
```

```
wilcox.test(despues, antes, paired = TRUE)
```

Inferencia estadística

Supuestos del test-t y como revisarlos

Supuesto	Como evaluarlo	Comentario practico
Independencia	Se evalua por diseño, no con un test.	Es el supuesto mas importante. Si falla, cambia el modelo.
Normalidad	Histograma, QQ-plot, shapiro.test().	El t-test es bastante robusto si n es moderado y no hay outliers extremos.
Homogeneidad de varianza	Boxplot, leveneTest().	Welch t-test relaja este supuesto.
Escala numerica	Variable continua o aproximadamente continua.	Para conteos o proporciones, considerar otros modelos.

```
ggplot(df, aes(sample = Sepal.Length)) + stat_qq() + stat_qq_line()
shapiro.test(df$Sepal.Length[df$Species == "setosa"])
car::leveneTest(Sepal.Length ~ Species, data = df)
```

Inferencia estadística

Alternativas no parametricas para comparar medias

- Estos tests no comparan estrictamente las medias en todos los casos. Evalúan diferencias en distribuciones, rangos o medianas bajo supuestos adicionales.

Caso	Test parametrico	Alternativa	Interpretacion practica
1 muestra	t-test de una muestra	Wilcoxon signed-rank	La distribucion esta centrada en un valor de referencia.
2 grupos independientes	t-test independiente	Mann-Whitney / Wilcoxon rank-sum	Un grupo tiende a tener valores mayores que otro.
2 condiciones pareadas	t-test pareado	Wilcoxon signed-rank pareado	Las diferencias pareadas tienden a ser positivas o negativas.
3+ grupos independientes	ANOVA	Kruskal-Wallis	Al menos un grupo tiende a tener valores distintos.
3+ condiciones pareadas	ANOVA medidas repetidas	Friedman	Al menos una condicion difiere en rangos.

```
wilcox.test(Sepal.Length ~ Species, data = df)
kruskal.test(Sepal.Length ~ Species, data = iris)
```

Consultas?