

Modelos lineales

Minería de datos

Alex Di Genova

Modelos lineales

Panorama general

- Los modelos lineales son una de las herramientas más útiles en minería de datos porque permiten relacionar variables, cuantificar efectos, generar predicciones e interpretar resultados. Aunque hoy existen algoritmos más complejos, comprender estos modelos sigue siendo esencial.
- La **regresión lineal simple** relaciona una variable respuesta continua (Y) con un solo predictor (X).
- La **regresión lineal múltiple** incorpora varios predictores y permite controlar por otras variables.
- La **regresión logística** modela probabilidades cuando la respuesta es binaria (0/1)

Introducción a regresiones lineales

- La regresión lineal es un método estadístico para modelar la relación entre una variable dependiente (Y) y una o más variables independientes ($X_1...X_n$)
- Aplicaciones:
- Análisis predictivo
- Manejo de riesgo
- Análisis de tendencias.

Supuesto de la regresión lineal

- Regresión lineal simple: modela la relación entre dos variables mediante una ecuación lineal.
- Regresión lineal múltiple: extiende la regresión lineal simple para incluir múltiples predictores.
- Supuestos:
- Linealidad
- Independencia
- homocedasticidad (misma varianza)
- Normalidad

Modelos lineales

Conexión a test-t y anova

- Esto conecta la comparación de medias, el ANOVA y la regresión.

Analisis clasico	Modelo equivalente	Interpretacion
t-test dos grupos	lm(y ~ grupo)	El coeficiente del grupo es la diferencia de medias.
ANOVA una via	lm(y ~ grupo)	Evalua si el factor grupo explica variacion en y.
Correlacion/regresion	lm(y ~ x)	El coeficiente beta indica cambio esperado en y por unidad de x.
ANCOVA	lm(y ~ grupo + covariable)	Compara grupos ajustando por otra variable.

```
fit_lm <- lm(Sepal.Length ~ Species, data = iris)
summary(fit_lm)
anova(fit_lm)
broom::tidy(fit_lm, conf.int = TRUE)
```

Ajustando un modelo Lineal en R

1.Preparación de datos

2. Ajustando el modelo

3. Evaluando el modelo

```
> glimpse(mtcars)
Rows: 32
Columns: 11
$ mpg <dbl> 21.0, 21.0, 22.8, 21.4, 18.7,...
$ cyl <dbl> 6, 6, 4, 6, 8, 6, 8, 4, 4, 6, 6, 8,...
$ disp <dbl> 160.0, 160.0, 108.0, 258.0,...
$ hp <dbl> 110, 110, 93, 110, 175, 105,...
$ drat <dbl> 3.90, 3.90, 3.85, 3.08, 3.15,...
$ wt <dbl> 2.620, 2.875, 2.320, 3.215,...
$ qsec <dbl> 16.46, 17.02, 18.61, 19.44....
$ vs <dbl> 0, 0, 1, 1, 0, 1, 0, 1, 1, 1, 1, 0...
$ am <dbl> 1, 1, 1, 0, 0, 0, 0, 0, 0, 0, 0,...
$ gear <dbl> 4, 4, 4, 3, 3, 3, 3, 4, 4, 4, 4,...
$ carb <dbl> 4, 4, 1, 1, 2, 1, 4, 2, 2, 4, 4,...
```

```
# Load necessary libraries
library(ggplot2)
```

```
# Load the data
data(mtcars)
head(mtcars)
```

```
# Fit a simple linear regression model
model <- lm(mpg ~ wt, data=mtcars)
```

```
# Summary of the model
summary(model)
```

```
# Plotting the data and the model
ggplot(mtcars, aes(x=wt, y=mpg)) +
  geom_point() +
  geom_smooth(method="lm", col="blue")
```


Ajustando un modelo lineal en R

mpg = rendimiento

wt = Peso del vehiculo

Call:

```
lm(formula = mpg ~ wt, data = mtcars)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-4.5432	-2.3647	-0.1252	1.4096	6.8727

Coefficients:


	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	37.2851	1.8776	19.858	< 2e-16 ***
wt	-5.3445	0.5591	-9.559	1.29e-10 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.046 on 30 degrees of freedom

Multiple R-squared: 0.7528, Adjusted R-squared: 0.7446

F-statistic: 91.38 on 1 and 30 DF, p-value: 1.294e-10



El patrón visual sugiere una tendencia lineal negativa:

los autos más pesados tienden a tener peor rendimiento.

Interpretación rápida del modelo: el intercepto (~37.29) representa el mpg esperado cuando `wt = 0`, valor que aquí no tiene una interpretación práctica directa. El coeficiente de `wt` (~ -5.34) indica que, en promedio, por cada unidad adicional de `wt` (mil libras), el rendimiento disminuye en aproximadamente 5.34 mpg.

Ajustando un modelo de regresion lineal múltiple en R

```
# Fit a multiple linear regression
model
model_mult <- lm(mpg ~ wt + hp +
qsec, data=mtcars)

# Summary of the model
summary(model_mult)

# Diagnostic plots
par(mfrow=c(2,2))
plot(model_mult)
```

Call:

```
lm(formula = mpg ~ wt + hp + qsec, data = mtcars)
```

Residuals:

Min	1Q	Median	3Q	Max
-3.8591	-1.6418	-0.4636	1.1940	5.6092

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	27.61053	8.41993	3.279	0.00278 **
wt	-4.35880	0.75270	-5.791	3.22e-06 ***
hp	-0.01782	0.01498	-1.190	0.24418
qsec	0.51083	0.43922	1.163	0.25463

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.578 on 28 degrees of freedom

Multiple R-squared: 0.8348, Adjusted R-squared: 0.8171

F-statistic: 47.15 on 3 and 28 DF, p-value: 4.506e-11

Interpretando los resultados

- Coeficientes:
 - Cada coeficiente representa el cambio esperado de la variable dependiente (Y) por una unidad de cambio en la variable independiente (X), manteniendo las demás variables constantes.
 - Si wt tiene un coeficiente de -4.35, significa que, por cada unidad de incremento en wt, mpg disminuye en 4.35 unidades, considerando las demás variables como constantes.

```
```{r}
Coefficients
coef(model_mult)
R-squared
summary(model_mult)$r.squared
P-values
summary(model_mult)$coefficients[,4]
```
```

| (Intercept) | wt | hp | qsec |
|-------------|-------------|-------------|------------|
| 27.61052686 | -4.35879720 | -0.01782227 | 0.51083369 |

[1] 0.8347678

| (Intercept) | wt | hp | qsec |
|--------------|--------------|--------------|--------------|
| 2.784556e-03 | 3.217222e-06 | 2.441762e-01 | 2.546284e-01 |

Interpretando los resultados

- R-cuadrado:
 - Indica la proporción de la varianza de la variable dependiente que es predecible a partir de las variables independientes.
 - Un valor de R-cuadrado de 0.83, significa que el 83% de la varianza en mpg es explicada por wt, hp y qsec.

```
```\r}  
Coefficients
coef(model_mult)
R-squared
summary(model_mult)$r.squared
P-values
summary(model_mult)$coefficients[,4]
```\r}
```

```
(Intercept)          wt          hp          qsec  
27.61052686 -4.35879720 -0.01782227  0.51083369  
[1] 0.8347678
```

```
(Intercept)          wt          hp          qsec  
2.784556e-03 3.217222e-06 2.441762e-01 2.546284e-01
```

Interpretando los resultados

- P-valor:
 - P-valor determina la significancia estadística de cada coeficiente. Un p-valor pequeño (generalmente < 0.05) indica evidencia fuerte en contra de la hipótesis nula, sugiriendo que el coeficiente es significativamente distinto de cero.
 - Si el p-valor de wt es 0.007, significa que existe un 0.007% de probabilidad de que wt no tenga un efecto en mpg, lo que indica significancia estadística.

```
```\r}\n# Coefficients\ncoef(model_mult)\n# R-squared\nsummary(model_mult)$r.squared\n# P-values\nsummary(model_mult)$coefficients[,4]\n```\n
```

```
(Intercept) wt hp qsec\n27.61052686 -4.35879720 -0.01782227 0.51083369\n[1] 0.8347678
```

```
(Intercept) wt hp qsec\n2.784556e-03 3.217222e-06 2.441762e-01 2.546284e-01
```




# Diagnóstico básico del modelo lineal

- Ajustar un modelo no basta: también debemos revisar si los supuestos son razonables.
- Análisis de residuos:
  - Residuals vs Fitted: ayuda a detectar curvatura o varianza no constante.
- Chequear supuestos:
  - Independencia: revisar la autocorrelación de las variables predictoras.
  - Homocedasticidad: revisar varianza en plot de residuales o comparar varianzas.
  - Normal Q-Q: compara los residuos con una distribución normal.


# Análisis de residuos

- Meta: Asegurar que los residuos distribuyen de forma aleatoria
- Código de ejemplo: `plot(model_mult, which=1) # Residuals vs Fitted plot`
- Buscar una distribución aleatoria de los residuos en la horizontal alrededor de 0.



# Normality of Residuals


- Goal: Residuals should be approximately normally distributed.
- Code : `qqnorm(resid(model_mult)) qqline(resid(model_mult))`
- Points should fall approximately along the reference line in a Q-Q plot.





# Homoscedasticity Check

- Goal: Residuals should have constant variance.
- Code: `plot(model_mult, which=3) # Scale-Location plot`
- Look for a horizontal line with equally spread points.



# Independence of Residuals

- Goal: Residuals should not be correlated.
- Code: `durbinWatsonTest(model_mult)`
- A Durbin-Watson statistic around 2 (1.5-2.5) suggests no autocorrelation

lag	Autocorrelation	D-W Statistic	p-value
1	0.2742427	1.422421	0.048




# Interacciones y términos no lineales

- Rara vez las relaciones son completamente aditivas. A veces el efecto de una variable depende del valor de otra. Eso se modela con interacciones.

```
modelo_interaccion <- lm(mpg ~ wt * am + hp, data = mtcars)
summary(modelo_interaccion)
```

```
Comparación con el modelo sin interacción
anova(modelo_multiple, modelo_interaccion)
```

Variable	Coeficiente	p-valor
Intercept	30.947	0.0
amManual	11.555	0.0078
wt	-2.516	0.0061
wt:amManual	-3.578	0.0197
hp	-27	0.0105



**Consultas?**