

Regresión Logística

Alex Di Genova

14/05/2026

Regresión logística


- En minería de datos solemos construir modelos con dos objetivos que a veces compiten: **explicar** un fenómeno y **predecir** datos nuevos.
- La regresión logística se usa cuando la variable de respuesta es binaria, por ejemplo: enfermedad/no enfermedad, compra/no compra, aprobado/reprobado, tumor metastásico/no metastásico.

Pregunta	Modelo/metodo	Salida principal	Como se evalua
¿Cuanto cambia Y continua al cambiar X?	Regresion lineal multiple (`lm`)	Coeficientes beta, R2, RMSE	ANOVA, t-test, AIC/BIC, validacion
¿Cuál es la probabilidad de una clase binaria?	Regresion logistica (`glm` binomial)	Probabilidad, log-odds, odds ratio	AIC/BIC, ROC/AUC, matriz de confusión
¿Que variables deberían quedarse en el modelo?	Selección automatica / regularizacion	Subconjunto o pesos penalizados	Criterio de informacion + validacion externa
El modelo más grande es mejor?	Comparación de modelos	Delta AIC/BIC, p de test anidado, metricas	Equilibrio ajuste, parsimonia e interpretabilidad

Regression logistica


Explicación o predicción

1. Definir la pregunta: explicación, predicción o ambas.
2. Definir la respuesta, los predictores, la unidad de observación y los datos disponibles
3. Separar los datos en entrenamiento y prueba si el objetivo es predictivo.
4. Ajustar modelos candidatos: simple, múltiple, con interacciones o con penalización.
5. Comparar modelos con criterios coherentes: prueba anidada, AIC/BIC, CV, RMSE, AUC, log-loss.
6. Diagnosticar problemas: outliers, colinealidad, separación, no linealidad, desbalance de clases.
7. Reportar los resultados con su interpretación, incertidumbre y limitaciones.



Regresión logística

- La regresión lineal no es ideal para una respuesta binaria porque puede predecir valores menores que 0 o mayores que 1 y porque el error no tiene varianza constante.
- La regresión logística modela directamente la **probabilidad** de que ocurra un evento.



Regresión logística

Formulación e interpretación

- **Log-Odds**

- Modela la probabilidad de que un dato dado pertenezca a una clase particular
- Odds = $p/1-p$ probabilidad de asignar a una clase
- Log-Odds = $\log(p/1-p) = \log(\text{Odds})$
- log-odds son modelados como una combinación lineal de las variables predictoras de entrada:
 - $\log(p/1-p) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n$

- **Sigmoid Function** (Función logística)

- Asigna los valores de log-odds a un valor de probabilidad entre 0 y 1
- $\sigma(z) = 1 / (1 + e^{-z})$ donde $z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n$

- **Clasificación binaria**

- Si la probabilidad es mayor que un cutoff (comúnmente > 0.5), el input es asignado a la clase 1; de lo contrario, clase 0.

- **Interpretación de coeficientes**

- Un coeficiente β_j representa el cambio en los **log-odds** del evento por una unidad adicional de x_j , manteniendo constantes las demás variables.
- Como los log-odds no son intuitivos, con frecuencia se reporta $\exp(\beta_j)$, llamado **odds ratio**.
- Si para una variable x se obtiene $\beta = 0.69$, entonces $OR = \exp(0.69) \approx 2$. Esto significa que, por cada unidad adicional de x , los odds del evento se multiplican por 2, manteniendo constantes las demás variables.

Cantidad	Como se obtiene	Interpretacion
Coeficiente beta	<code>`coef(modelo)`</code>	Cambio en log-odds por una unidad de X.
Odds ratio	<code>`exp(coef(modelo))`</code>	Factor multiplicativo sobre los odds. OR > 1 aumenta odds; OR < 1 disminuye odds.
IC 95% del OR	<code>`exp(confint(modelo))`</code>	Rango plausible para el OR. Si incluye 1, la evidencia es más débil.
Probabilidad predicha	<code>`predict(modelo, type = "response")`</code>	Probabilidad estimada de clase 1 para cada observación.

Regresión logística

Predecir si un estudiante aprobará(1) o reprobó(0) un control

Datos:

Hours Studied (x)	Pass/Fail (y)
1	0
2	0
3	0
4	1
5	1
6	1
7	1

1. Log-odds:

$$1. \log(1/1-p) = \beta_0 + \beta_1 \text{ Hours Studied}$$

2. Función Sigmoid:

$$1. p = \sigma(\beta_0 + \beta_1 \cdot \text{Hours Studied}) = 1 / (1 + e^{-(\beta_0 + \beta_1 \cdot \text{Hours Studied})})$$

3. Clasificación Binaria:

1. Si $p \geq 0.5$ predice Aprueba (1). Else reprueba (0).

4. Asumamos que el modelo fue entrenado y los parámetros son:

$$1. \beta_0 = -6 \text{ y } \beta_1 = 1$$

Regresión logística

Predecir si un estudiante aprobará(1) o reprobará(0) un control

Data:

Hours Studied (x)	Pass/Fail (y)
1	0
2	0
3	0
4	1
5	1
6	1
7	1

1. Ejemplo de Predicción

1. Para un estudiante que dedicó 3 horas

2. Log-odds:

$$1. z = \log(1/1-p) = \beta_0 + \beta_1 3 = -6 + 1 \cdot 3 = -3$$

3. Función Sigmoid:

$$1. p = \sigma(-3) = 1 / (1 + e^{-(-3)}) = 1 / (1 + e^3) = 1/21.08 = 0.04$$

4. Clasificación binaria:

1. Como $0.04 < 0.5$, el modelo predice que reprobará.

Diagnóstico y evaluación de modelos logísticos

Métricas básicas de clasificación


Metrika	Formula/idea	Cuando usarla con cuidado
Accuracy	Proporción total de aciertos	Puede resultar engañosa con clases desbalanceadas.
Sensibilidad / Recall	$TP / (TP + FN)$	Es importante si perder positivos es costoso.
Especificidad	$TN / (TN + FP)$	Importante si los falsos positivos son costosos.
Precisión / PPV	$TP / (TP + FP)$	Depende mucho de la prevalencia.
F1-score	Media armonica entre precisión y recall	Util cuando clase positiva es relevante y desbalanceada.
AUC ROC	Capacidad de discriminar positivos sobre negativos	No fija un umbral y puede ocultar mala calibración.
Log-loss	Penaliza probabilidades incorrectas con alta confianza	Buena para evaluar probabilidades, no solo clases.

TP (**Verdadero Positivo**): Positivo predicho correctamente.

FP (**Falso Positivo**): Positivo predicho incorrectamente, por ejemplo, un correo bueno marcado como spam.

FN (**Falso Negativo**): Negativo predicho incorrectamente, por ejemplo, un correo spam que pasa el filtro.

TN (**Verdadero Negativo**): Negativo predicho correctamente, por ejemplo, un correo bueno que permanece en la bandeja de entrada.



**[https://github.com/adigenova/
uohdm/blob/main/code/
modelos_lineales_y_regresion_lo
gistica_colab.ipynb](https://github.com/adigenova/uohdm/blob/main/code/modelos_lineales_y_regresion_logistica_colab.ipynb)**

Consultas?