

Selección de variables y comparación automática de regresiones

Alex Di Genova

Comparación de modelos

- En regresión queremos explicar o predecir una respuesta usando varias covariables.
- Un modelo demasiado simple puede dejar fuera señales importantes.
- Un modelo demasiado complejo puede ajustarse muy bien a los datos de entrenamiento, pero puede fallar con datos nuevos.
- La pregunta central no es “¿qué modelo ajusta mejor?”, sino “¿qué modelo generaliza mejor y es interpretable?”.

Criterios para comparar modelos

Ajuste explicativo

- R^2 ajustado: penaliza modelos con demasiadas variables.
- AIC/BIC: menor valor indica mejor balance ajuste-complejidad.
- ANOVA entre modelos anidados: prueba si la variable extra mejora el modelo.

Desempeño predictivo

- RMSE/MAE para regresión continua.
- Accuracy, ROC-AUC y log-loss en clasificación.
- Validación cruzada para estimar desempeño fuera de muestra.

Criterio	Premia	Penaliza	Uso típico
AIC	Buen ajuste	Número de parámetros	Comparar modelos predictivos candidatos
BIC	Buen ajuste	Complejidad con penalización más fuerte	Buscar modelos más parsimoniosos
CV / test	Buen desempeño fuera de muestra	Sobreajuste indirectamente	Elegir modelos para predicción

- Regla práctica: Use criterios de información para comparar ajuste-complejidad y validación cruzada para estimar desempeño fuera de muestra.

AIC y BIC: idea e interpretación

- AIC y BIC comparan modelos ajustados sobre los mismos datos y la misma variable de respuesta.
 - $AIC = 2k - 2 \ln(L)$ - Akaike information criterion (AIC) k =parametros L = maximized value of model
 - $BIC = k \ln(n) - 2 \ln(L)$ Bayesian information criterion k =parametros n =observaciones
- Ambos combinan dos fuerzas: mejor ajuste versus menor complejidad.
- Menor AIC o menor BIC indica mejor balance relativo entre ajuste y complejidad.
- No tienen interpretación absoluta: sirven para comparar modelos candidatos.
- BIC suele preferir modelos más simples porque penaliza más cuando aumenta el tamaño muestral.

Modelos lineales

Ejemplo 1

```
data(mtcars)
mtcars <- mtcars %>%
  mutate(am = factor(am, labels = c("auto", "manual")),
         cyl = factor(cyl))

m0 <- lm(mpg ~ 1, data = mtcars)
m1 <- lm(mpg ~ wt, data = mtcars)
m2 <- lm(mpg ~ wt + hp + cyl, data = mtcars)
m3 <- lm(mpg ~ wt + hp + cyl + am + qsec, data = mtcars)

modelos <- list(nulo = m0, simple = m1, multiple = m2, completo = m3)

map_df(modelos, glance, .id = "modelo") %>%
  select(modelo, r.squared, adj.r.squared, AIC, BIC, sigma, p.value) %>%
  arrange(AIC)
```

modelo <chr>	r.squared <dbl>	adj.r.squared <dbl>	AIC <dbl>	BIC <dbl>	sigma <dbl>	p.value <dbl>
multiple	0.8572195	0.8360668	154.4692	163.2636	2.440231	4.869142e-11
completo	0.8721353	0.8414477	154.9385	166.6644	2.399848	5.195768e-10
simple	0.7528328	0.7445939	166.0294	170.4266	3.045882	1.293959e-10
nulo	0.0000000	0.0000000	208.7555	211.6870	6.026948	NA

Comparación modelos anidados con anova

```
# m2 está contenido dentro de m3: m3 agrega am y qsec  
anova(m2, m3)  
  
# Interpretación:  
# H0: las variables agregadas no reducen significativamente el RSS.  
# H1: al menos una de las variables agregadas mejora el modelo.
```

Analysis of Variance Table

Model 1: mpg ~ wt + hp + cyl

Model 2: mpg ~ wt + hp + cyl + am + qsec

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	27	160.78				
2	25	143.98	2	16.796	1.4582	0.2518

Selección Stepwise

- Stepwise construye o simplifica modelos agregando y/o quitando variables según un criterio como AIC.
- Backward: parte con el modelo completo y elimina variables.
- Forward: parte con un modelo nulo o simple y agrega variables.
- Both: combina eliminación y adición en cada paso.
- Es útil como exploración rápida, pero puede ser inestable con variables correlacionadas.

Selección stepwise usando AIC

```
modelo_full <- lm(mpg ~ wt + hp + cyl + am + qsec + disp + drat + gear + carb,  
  data = mtcars)  
modelo_null <- lm(mpg ~ 1, data = mtcars)  
  
step_aic <- stepAIC(modelo_null,  
  scope = list(lower = modelo_null, upper = modelo_full),  
  direction = "both",  
  trace = FALSE)  
  
summary(step_aic)  
glance(step_aic)  
tidy(step_aic, conf.int = TRUE)
```

Call:

```
lm(formula = mpg ~ wt + cyl + hp + am, data = mtcars)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-3.9387	-1.2560	-0.4013	1.1253	5.0513

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	33.70832	2.60489	12.940	7.73e-13	***
wt	-2.49683	0.88559	-2.819	0.00908	**
cyl6	-3.03134	1.40728	-2.154	0.04068	*
cyl8	-2.16368	2.28425	-0.947	0.35225	
hp	-0.03211	0.01369	-2.345	0.02693	*
ammanual	1.80921	1.39630	1.296	0.20646	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.41 on 26 degrees of freedom
Multiple R-squared: 0.8659, Adjusted R-squared: 0.8401
F-statistic: 33.57 on 5 and 26 DF, p-value: 1.506e-10

Ventajas y límites del stepwise

- Ventaja: es simple, rápido y útil para construir una primera línea base.
- Límite: puede ser inestable si hay variables correlacionadas o pocas muestras.
- Límite: no garantiza encontrar el mejor modelo global.
- Buena práctica: usarlo como exploración, no como única evidencia.

Stepwise

Limites

- Puede elegir variables distintas si cambia levemente la muestra.
- Puede inflar la confianza en los p-values porque el modelo fue elegido mirando los datos.
- No maneja bien colinealidad fuerte: variables equivalentes pueden competir entre sí.
- No garantiza encontrar el mejor modelo global si el espacio de modelos es grande.
- Debe reportarse como procedimiento exploratorio y validarse con test set o validación cruzada

Riesgo	Qué hacer
Sobreajuste	Separar train/test o usar validación cruzada
Colinealidad	Revisar correlaciones, VIF o usar regularización
Selección inestable	Comparar con LASSO / Elastic Net
Interpretación exagerada	Reportar incertidumbre y justificar biológicamente/ teóricamente

Métodos de regresión penalizada

Ridge, LASSO y Elastic Net

- La idea central es que, en vez de ajustar una regresión lineal normal usando solo el error, se agrega una **penalización** al tamaño de los coeficientes.

- En regresión lineal clásica se busca minimizar:

$$• \quad RSS = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- En regresión penalizada se minimiza algo como:

- $RSS + \text{penalización}$

- La penalización evita modelos demasiado complejos y ayuda cuando hay muchas variables, variables correlacionadas o riesgo de sobreajuste.

Métodos de regresión penalizada

Ridge

- **Ridge** agrega una penalización al cuadrado de los coeficientes:

$$RSS + \lambda \sum_{j=1}^p \beta_j^2$$

- Esto castiga coeficientes grandes. Mientras más grande es λ , más fuerte es la penalización.
- Intuición: Ridge no elimina variables. Lo que hace es **achicar los coeficientes** hacia cero.

Variable	Coeficiente	Coeficiente Ridge
edad	4.2	2.1
peso	8.5	4.3
presión	-6.1	-3.0

Las variables siguen estando en el modelo, pero con efectos más moderados.

¿Cuándo conviene Ridge?

- Hay muchas variables predictoras.
- Las variables están correlacionadas entre sí.
- No necesariamente queremos seleccionar variables, sino mejorar la capacidad predictiva.

Por ejemplo, si tenemos variables como peso, IMC, perímetro abdominal y porcentaje de grasa, todas están relacionadas. Ridge reparte el efecto entre ellas en vez de elegir solo una.

Métodos de regresión penalizada

LASSO

- **LASSO** significa Least Absolute Shrinkage and Selection Operator.
- **LASSO** agrega una penalización con el valor absoluto de los coeficientes:

$$RSS + \lambda \sum_{j=1}^p |\beta_j|$$

- Intuición: **LASSO** también achica coeficientes, pero además puede hacer que algunos coeficientes queden exactamente en cero.
- **LASSO** realiza selección automática de variables.

Variable	Coeficiente	Coeficiente LASSO
edad	4.2	3.1
peso	8.5	6.7
presión	-6.1	-4.2
colesterol	0.8	0
altura	0.3	0

¿Cuándo conviene LASSO?

- Queremos seleccionar variables relevantes.
- Tenemos muchas variables y sospechamos que solo algunas son realmente importantes.
- Queremos un modelo más simple e interpretable.

Por ejemplo, en un dataset con 100 variables clínicas, LASSO puede ayudar a seleccionar un subconjunto pequeño que predice mejor una enfermedad.

Métodos de regresión penalizada

Elastic Net

- **Elastic Net** combina Ridge y LASSO.
- Su penalización es una mezcla de ambas:
$$RSS + \lambda \left[\alpha \sum_{j=1}^p |\beta_j| + (1 - \alpha) \sum_{j=1}^p \beta_j^2 \right]$$
- λ controla la fuerza total de la penalización.
- α controla cuánto se parece el modelo a Ridge o a LASSO.
- Intuición:
 - Elastic Net busca un equilibrio.
 - Como LASSO, puede seleccionar variables.
 - Como Ridge, maneja mejor grupos de variables correlacionadas.
 - Es muy útil cuando tenemos muchas variables y varias están correlacionadas entre sí.

Situación	Método recomendado
Muchas variables correlacionadas	Ridge o Elastic Net
Quiero selección automática de variables	LASSO
Quiero selección, pero hay correlación entre variables	Elastic Net
Me interesa más predicción que interpretación	Ridge o Elastic Net
Me interesa un modelo simple e interpretable	LASSO

Ejemplo con mtcars

Variables seleccionadas por cada modelo

LASSO y Elastic Net pueden dejar coeficientes exactamente en cero

Variable	Estado							
	No seleccionada				Seleccionada			
wt	-1.87	-2.48	-3.05	-2.61	-3.81	-3.81	-0.84	-1.31
vs	0.6	1.05	0.26	1.05	1.75	1.75	0.92	0.93
qsec	0	0.27	0	0.24	0.65	0.65	0.16	0.19
hp	-0.02	-0.03	-0.02	-0.03	-0.05	-0.05	-0.01	-0.01
gear	0	0.39	0	0.28	0.76	0.76	0.5	0.62
drat	0.71	0.37	0.35	0.22	0.03	0.03	0.99	1.01
disp	-0.01	0	0	0	0.01	0.01	-0.01	-0.01
cyl8	0	0	0	0	1.64	1.64	-0.95	-0.8
cyl6	0	-1.59	0	-1.68	-1.66	-1.66	-0.61	-1.32
carb	-0.17	-0.09	0	0	0.51	0.51	-0.35	-0.51
ammanual	0.72	2.06	0	2.02	2.62	2.62	1.14	1.7

lambda.min busca el modelo con el menor error predictivo.

lambda.1se busca un modelo más simple, aceptando un error

Comparación automática en train/test

- Para predicción, la honesta usa datos para ajustar el modelo.

- Se puede dividir en prueba o usar validación

- En regresión lineal como RMSE o MAE

```
255 `r testt`
256 set.seed(123)
257 df=mtcars
258 idx <- createDataPartition(df$mpg, p = 0.75, list = FALSE)
259 train <- df[idx, ]
260 test <- df[-idx, ]
261 #modelos
262 simple = lm(mpg ~ wt, data = train)
263 multiple = lm(mpg ~ wt + hp + am, data = train)
264 full = lm(mpg ~ wt + hp + am + qsec + cyl + disp + drat, data = train)
265
266 pred <- predict(simple, newdata = test)
267 a=tibble(modelo = "simple", RMSE = RMSE(pred, test$mpg), AIC = AIC(simple))
268 pred <- predict(multiple, newdata = test)
269 b=tibble(modelo = "multiple", RMSE = RMSE(pred, test$mpg), AIC = AIC(simple))
270 pred <- predict(full, newdata = test)
271 c=tibble(modelo = "full", RMSE = RMSE(pred, test$mpg), AIC = AIC(simple))
272
273 bind_rows(a,b,c)
```

- Un modelo con menor AIC no siempre tendrá menor RMSE en test.

- La decisión final debe combinar desempeño, simplicidad e interpretabilidad.

	RMSE	AIC
simple	2.582794	126.3123
multiple	2.939367	126.3123
full	2.582794	126.3123

Flujo recomendado

- 1) Definir el objetivo: explicación, predicción o ambas.
- 2) Separar datos de entrenamiento/prueba o usar validación cruzada.
- 3) Proponer modelos candidatos: simple, múltiple, stepwise, Ridge, LASSO y Elastic Net.
- 4) Comparar con AIC/BIC solo cuando los modelos usan la misma respuesta y los mismos datos.
- 5) Comparar desempeño predictivo con RMSE, MAE, accuracy o AUC según corresponda.
- 6) Revisar diagnóstico, colinealidad, residuos e interpretación de coeficientes.
- 7) Reportar el modelo final explicando por qué se eligió y qué limitaciones tiene.

Consultas?