

Mineria de Datos: PCA I



Alex Di Genova

02/06/2026

Algoritmos en minería de Datos

Clases

- Supervisados
 - Clasificación
 - Regresión
- No-Supervisados
 - Reducción de dimensionalidad
 - Clustering
- Semi-supervisados



Ajustando un modelo lineal en R

1.Preparacion de datos

2.Adjustar el modelo

3.Evaluar el modelo

```
> glimpse(mtcars)
```

```
Rows: 32
```

```
Columns: 11
```

```
$ mpg <dbl> 21.0, 21.0, 22.8, 21.4, 18.7,...
```

```
$ cyl <dbl> 6, 6, 4, 6, 8, 6, 8, 4, 4, 6, 6, 8,...
```

```
$ disp <dbl> 160.0, 160.0, 108.0, 258.0,...
```

```
$ hp <dbl> 110, 110, 93, 110, 175, 105,...
```

```
$ drat <dbl> 3.90, 3.90, 3.85, 3.08, 3.15,...
```

```
$ wt <dbl> 2.620, 2.875, 2.320, 3.215,...
```

```
$ qsec <dbl> 16.46, 17.02, 18.61, 19.44....
```

```
$ vs <dbl> 0, 0, 1, 1, 0, 1, 0, 1, 1, 1, 0...
```

```
$ am <dbl> 1, 1, 1, 0, 0, 0, 0, 0, 0, 0, 0,...
```

```
$ gear <dbl> 4, 4, 4, 3, 3, 3, 3, 4, 4, 4, 4,...
```

```
$ carb <dbl> 4, 4, 1, 1, 2, 1, 4, 2, 2, 4, 4,...
```

```
# Load necessary libraries  
library(ggplot2)
```

```
# Load the data  
data(mtcars)  
head(mtcars)
```

```
# Fit a simple linear regression model  
model <- lm(mpg ~ wt, data=mtcars)
```

```
# Summary of the model  
summary(model)
```

```
# Plotting the data and the model  
ggplot(mtcars, aes(x=wt, y=mpg)) +  
  geom_point() +  
  geom_smooth(method="lm", col="blue")
```

Ajustando un modelo lineal en R

Call:

```
lm(formula = mpg ~ wt, data = mtcars)
```

Residuals:

Min	1Q	Median	3Q	Max
-4.5432	-2.3647	-0.1252	1.4096	6.8727

Coefficients:


	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	37.2851	1.8776	19.858	< 2e-16 ***
wt	-5.3445	0.5591	-9.559	1.29e-10 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.046 on 30 degrees of freedom

Multiple R-squared: 0.7528, Adjusted R-squared:
0.7446

F-statistic: 91.38 on 1 and 30 DF, p-value: 1.294e-10



Regression multiple en R

```
# Fit a multiple linear regression  
model  
model_mult <- lm(mpg ~ wt + hp  
+ qsec, data=mtcars)
```

```
# Summary of the model  
summary(model_mult)
```

```
# Diagnostic plots  
par(mfrow=c(2,2))  
plot(model_mult)
```

Call:

```
lm(formula = mpg ~ wt + hp + qsec, data = mtcars)
```

Residuals:

Min	1Q	Median	3Q	Max
-3.8591	-1.6418	-0.4636	1.1940	5.6092

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	27.61053	8.41993	3.279	0.00278 **
wt	-4.35880	0.75270	-5.791	3.22e-06 ***
hp	-0.01782	0.01498	-1.190	0.24418
qsec	0.51083	0.43922	1.163	0.25463

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.578 on 28 degrees of freedom
Multiple R-squared: 0.8348, Adjusted R-squared: 0.8171
F-statistic: 47.15 on 3 and 28 DF, p-value: 4.506e-11

Como seleccionar características?


- **Conocimiento del dominio del problema.**
- **Analisis de correlación**
 - `cor_matrix <- cor(dataset)` `cor_matrix["target_variable", ]`
- **Selección automatica (Stepwise)**
 - Agregar o remover características con criterios estadísticos (e.g., AIC, BIC).

```
model <- lm(target_variable ~ ., data=dataset)
step_model <- stepAIC(model, direction="both")
summary(step_model)
```
- **Regresiones penalizadas (Ridge, LASSO,)**
- **Metodos basados en arboles**
 - La importancia de las características puede ser determinada entrenando un Random Forests
- **PCA (Analisis de componentes principales)**
 - Reduce la dimensionalidad maximizando la varianza explicada.
 - Usar los componentes como características.
- **Valores SHAP**


PCA: Analisis de componentes principales

Reducción de dimensionalidad

- La **reducción de dimensionalidad** comprende un conjunto de métodos que transforman un conjunto de variables, potencialmente muchas, en un número menor de variables que conservan la mayor cantidad posible de la información original.
- Sus objetivos principales son:
 - Facilitar la visualización de datos con muchas variables.
 - Mitigar la llamada maldición de la dimensionalidad.
 - Reducir los efectos de la **colinealidad** entre variables.



Representacion de datos en Matriz



$$X = \begin{matrix} & \overbrace{\hspace{2cm}}^n \\ \left[\begin{array}{ccc} x_{11} & \dots & x_{1n} \\ x_{21} & \dots & x_{2n} \\ \dots & \dots & \dots \\ x_{p1} & \dots & x_{pn} \end{array} \right] & \left. \vphantom{\begin{array}{ccc} x_{11} & \dots & x_{1n} \\ x_{21} & \dots & x_{2n} \\ \dots & \dots & \dots \\ x_{p1} & \dots & x_{pn} \end{array}} \right\} p \end{matrix}$$


x_{ij} : value of variable i for individual j .
→ e.g. value of gene i for sample j

- Or transposed, $n \times p$.

Vocabulario básico


- **Varianza:** medida de dispersión para una variable x

$$Var(X) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \quad \text{with} \quad \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$




- **Covarianza:** Medida de asociación entre dos variables x e y

$$Cov(X, Y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n}$$





- **Correlación:** covarianza estandarizada entre -1 y 1

$$Cor(X, Y) = \frac{Cov(X, Y)}{\sigma_X \sigma_Y} \quad \text{with} \quad \sigma_X = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}}$$



Selección vs extracción de características

- Selección: determinar un conjunto más pequeño de características minimizando la pérdida de información.
- Extracción: transformar las variables originales en un nuevo conjunto de variables mediante combinaciones lineales o no lineales: $y_1 = \alpha_1 * x_1 + \alpha_2 * x_2 + \alpha_3 * x_3 + \dots$




Reducción de dimensionalidad

- Problema: n muestras, p variables cuantitativas (e.g. peptides, proteins, metabolites, mRNA, ...)

Visualize pairwise relations by scatter plots

But when p is large ?


$p=2$



- Cuando un dataset tiene muchas dimensiones (p), necesitamos reducirlas a un conjunto más pequeño de variables relevantes, que capturen la mayor parte de la información o variabilidad de los datos, pero sin incluir información redundante.”


PCA

- El Análisis de Componentes Principales, o PCA, es un método para reducir la dimensionalidad de un conjunto de datos, aumentando su interpretabilidad y minimizando la pérdida de información.
- PCA transforma los datos a un nuevo sistema de coordenadas.
- Crea nuevas variables que son combinaciones lineales de las variables originales.
- Estas nuevas variables explican la mayor parte de la variación o información presente en los datos.




PCA

Sub-optimal component





Optimal component



- $PC1 = 0.95 \text{ var1} + (-0.32) \text{ var2}$

PCA

Idea



$$PC_1 = \alpha_1 * x_1 + \alpha_2 * x_2 + \alpha_3 * x_3 + \dots$$

- Encontrar ejes ortogonales, llamados componentes principales, sobre los cuales se pueden proyectar las observaciones para obtener un espacio comprensible de menor dimensión.

Calculando un PCA

$$z = \frac{x - \mu}{\sigma}$$

- 1. Estandarizar los datos.
- 2. Calcular la matriz de covarianza.
- 3. Calcular los valores propios y los vectores propios. $A = \begin{bmatrix} \text{var}(x) & \text{cov}(x, y) & \text{cov}(x, z) \\ \text{cov}(x, y) & \text{var}(y) & \text{cov}(y, z) \\ \text{cov}(x, z) & \text{cov}(y, z) & \text{var}(z) \end{bmatrix}$
- 4. Ordenar los valores propios de mayor a menor junto con sus vectores propios asociados, y seleccionar los primeros k componentes principales.



Vector Propio (Eigenvector): Es una **dirección** en el espacio de los datos. En PCA, cada vector propio es un **Componente Principal**. Indica hacia dónde apunta la máxima varianza de los datos. Los vectores propios son **ortogonales** (perpendiculares entre sí). $\rightarrow \text{solve } |A - \lambda \cdot I| = 0$

Valor Propio (Eigenvalue): Es un **escalar** (un número) asociado a cada vector propio. Representa la **cantidad de varianza** que captura ese componente Principal. A mayor valor propio, más información (varianza) explica ese componente.

- 5. Proyectar los datos sobre los ejes definidos por los componentes principales

Gráficos de PCA



- Cada punto es una observación
- Nuevo sistema de coordenadas (PC1, PC2...)
- Flechas rojas = contribución de cada variable inicial.
- Varios gráficos en 2D :
 - PC1/PC2
 - PC1/PC3
 - PC2/PC3



Componentes PCA




- Contribución de cada variable inicial al componente: α , β , γ ...son coeficientes ttambién llamados “loadings”
- Algunas variables contribuyen en la misma dirección a ciertos componentes principales (e.g., waist and height for PC1), pero en dirección opuesta en otros, como PC5.
- Los componentes principales son ortogonales entre sí: no hay redundancia de información entre ellos.

$$PC_i = \alpha_i \cdot \text{age} + \beta_i \cdot \text{chol} + \gamma_i \cdot \text{height} + \delta_i \cdot \text{waist} + \epsilon_i \cdot \text{weight}$$



Componentes PCA


- Cada componente explica alguna parte de la varianza total del dataset
- La varianza explicada es proporcional al valor propio correspondiente.
- Los componentes se ordenan por valor propio en orden decreciente.



Considering PC1 & PC2 explains 63% of the total variance

Cuántos componentes?

- Varios criterios para seleccionar un set optimo de CP sin perder mucha información.
- Proporción total de varianza: mantener los componentes que explican X% de la varianza ($> 3\%$)
- Promedio de los valores propios: mantener los CP con valores propios mayores que:
 - promedio (Kaiser rule) or
 - 70% del promedio del valor propio (Jottcliffe rule)



Paquetes R para PCA

- *prcomp()* and *princomp()* [built-in R *stats* package],
- *PCA()* [*FactoMineR* package],
- *dudi.pca()* [*ade4* package],
- and *epPCA()* [*ExPosition* package]
- *PCAtools* [<https://bioconductor.org/packages/release/bioc/vignettes/PCAtools/inst/doc/PCAtools.html>]

Un flujo util:

No supervisado -> supervisado

- Comenzar el análisis con técnicas no supervisadas:
 - Reducir el número de dimensiones
 - Determinar grupos
 - Determinar características importantes
- Luego usar metodos supervisados (regresion, ml, estadística etc)

Questions?
Practice!!!