

Mineria de datos: Clustering I



Alex Di Genova

16/06/2026

Algoritmos en MD

Clases

- Supervisados
 - clasificacion
 - Regresion
- No-Supervisados
 - Reduccion Dimension
 - Clustering
- Semi-supervisados




Que es clustering?

- Un clúster es un set de casos que son más similares entre ellos que a cualquier otro caso de otro clúster.
- Usamos clustering, cuando no conocemos las clases o el número de clases en los datos.
- Algunos métodos:
 - Clustering encontrando centros: k-means
 - Clustering Jerárquico
 - Clustering basado en densidad: DBSCAN y OPTICS
 - Clustering basado en distribuciones con modelamiento mixto


K-Means

- El clustering K-means es un método no supervisado para particionar un conjunto **de datos en k** clusters distintos.
 - **Inicialización:** Elegir el número de clústeres k y inicializar aleatoriamente los centroides (centros de los clústeres).
 - **Asignar:** Asignar cada dato al centroide más cercano usando la distancia euclidiana. Esto forma k clusters.
 - **Actualizar:** Recalcular los centroides como el promedio de todos los datos asignados a cada clúster.
 - **Repetir:** Repetir los pasos de asignación y actualización hasta que los centroides no cambien significativamente o se alcance el número máximo de iteraciones.
 - **Convergencia:** El algoritmo converge cuando los centroides se estabilizan o los cambios en las posiciones caen por debajo de un umbral.
- El resultado es un set de cluster que minimiza la varianza intra-cluster (o las diferencias cuadráticas)



K-Means


Como elegir el numero optimo de clusters



- Clustering de **buena calidad** típicamente significa que cada clúster es tan compacto como sea posible, mientras que las distancias entre clústeres son tan grandes como sea posible.
- Una estrategia común es calcular múltiples modelos de clusters (2, 3, 4, 5...) y comparar métricas de cluster para seleccionar el modelo con mejor fit en los datos.
 - Indice Davies-Bouldin
 - Indice Dunn
 - Pseudo F statistic

K-Means

Como elegir el numero optimo de clusters




- Índice de Davies-Bouldin: cuantifica la separación promedio de cada clúster, considerando el más cercano (valores pequeños son mejores).
- Índice Dunn: cuantifica la razón entre la menor distancia entre puntos pertenecientes a distintos clústeres y la mayor distancia dentro de cualquiera de los clústeres. Mientras más alto, mejor.
- Pseudo F statistic: cuantifica la razón entre la varianza entre clústeres y la varianza dentro de los clústeres. Mientras más alto, mejor.

Cluster jerarquizo

- Aglomerativo (de abajo hacia arriba)
 - Comienza con cada punto de datos como un clúster individual.
 - Fusiona iterativamente los pares de clústeres más cercanos entre sí.
 - Continúa hasta que todos los puntos se fusionen en un único clúster o se alcance un número específico de clústeres.
- divisivo (de arriba hacia abajo):
 - Comienza con todos los puntos de datos en un único clúster.
 - Divide iterativamente el clúster más adecuado en clústeres más pequeños.
 - Continúa hasta que cada punto sea su propio clúster o hasta alcanzar un número específico de clústeres.”Starts with all data points in a single cluster.

Dendrogram for USArrests (Complete Linkage)



AHC

Pasos del clustering jerárquico aglomerativo

1. Calcular la matriz de distancias:

- Calcular las distancias entre pares de puntos de datos usando una métrica de distancia, por ejemplo, la distancia euclidiana.

2. Crea clusters:

- Cada punto de datos comienza como un clúster propio.

3. Fusionar Clusters:

- Encontrar el par de clústeres con la menor distancia entre sí y fusionarlos.
- Actualizar la matriz de distancias para reflejar la fusión.

4. Repetir:

- Repetir el proceso de fusión hasta que todos los puntos estén en un único clúster.

5. Formar el dendrograma:

- Un dendrograma es un diagrama en forma de árbol que representa la secuencia de fusiones o divisiones. Ayuda a visualizar el proceso de clustering y a decidir el número de clústeres.

Consultas?
Practicar!!!